Agentic Image Generation v3

多模态 DAG、27B 控制器、9B 生成器与联合学习

完整研究设计与实施规范 | 2026 年 10 月 · v3 定稿（最终审查完成）

本文面向一台4×A6000 48GB服务器和一台3×RTX5090 32GB服务器。当前交付是研究、设计与验证计划；本轮执行了公开源码与元数据检查、CPU数学/接口算术，未加载研究模型或启动训练。所有性能、显存峰值和收益验收均明确列为待在目标机器执行。

目录

Agentic Image Generation v3 **1**
0. 方案的主线：让意图、条件和证据对应起来 . . . 2
1. 主配置与模型选择 . . . 3
2. 系统组成、固定版本与复用方式 . . . 3
3. 任务、身份、工件与 DAG 的完整语义 . . . 5
4. 动作协议、状态机与错误定位 . . . 7
5. 多模态接口与几何约定 . . . 10
6. 可训练参数、27B量化适配与参考模型 . . . 12
7. 数据来源、隔离、构建与筛选 . . . 17
8. 两侧 SFT 的精确定义 . . . 20
9. 评价器、工具接口与奖励可靠性 . . . 22
10. 回报定义及边界情况 . . . 23
11. 行为记录与联合概率 . . . 24
12. Flow-SDE 的完整数学与实现 . . . 26
13. 分层采样、信用分配、损失与正则 . . . 28
14. 等价的低显存反向计算 . . . 30
15. 训练阶段、采样更新与一致提交 . . . 32
16. 失败、重试、零信号和终止 . . . 33
17. 两台服务器的职责、资源与默认配置 . . . 34
18. 有明确接口的扩展 . . . 38
19. 实施模块、依赖顺序与集中验收 . . . 39
20. 基线、消融、统计与问题排查 . . . 40
21. 源码差异、采用范围与具体修复 . . . 42
22. 固定来源与检索定位 . . . 43
23. 本轮真实核验记录与交付边界 . . . 45

0. 方案的主线：让意图、条件和证据对应起来

这个系统要完成一件清楚的事：**理解复杂图像要求，提出可执行的生成计划，看见执行结果，修订造成问题的相关分支，并从这些真实交互中同时改进规划与生成。**

主模型确定为 **Qwen3.8-27B控制器、FLUX.2-klein-base-9B生成器、冻结Qwen3-VL-32B评价器**。27B与32B采用固定NF4底座；27B训练语言LoRA，32B只做判定；9B保留BF16底座并训练DiT LoRA。这利用现有七张卡的单卡容量和服务分工，不要求大规模模型并行。S1 S2 S23

0.1 三层状态、一条闭环

DAG保存三层相互对应的状态：

层	保存的内容	在闭环中的作用
意图	原始要求、实体、关系、子任务、控制选择	解释“要完成什么”；原文固定，Agent计划可修订
条件	实际布局、source/target mask、参考绑定、文本块、latent与位置IDs	精确决定“这一次让生成器执行什么”；由确定性编译器构造
证据	图像版本、公开检查、裁剪/检测、失败与修复结果	支持“哪里有问题、下一步改什么”；每条证据绑定真实图像与版本

一次修复依次完成：找到失败证据关联的可修改节点，提出patch，编译变更后的条件，执行一次图像操作，检查结果，选择保留、回退或交付。旧版本继续存在，重算范围由依赖决定。DAG因此既组织执行，也保留学习需要的真实决策上下文。

模型之间传递的是有类型、带坐标和来源的工件。JSON表达动作与引用，RGB、mask、latent、embedding和attention可见域按固定张量接口传输；视觉模型可以重新看原图与当前图，生成器可以直接消费空间和参考条件。

0.2 三个学习阶段分别解决什么

1. **联结的双侧SFT。**同一个任务的公开PLAN同时成为控制器示范和生成器条件来源。控制器学习提出可执行计划；生成器学习执行同一种编译条件。真实失败状态进一步教修复、回退和结束。两项监督损失各自有梯度，数据通过同一bundle关联。
2. **Agent RL。**暂时固定经过SFT的生成器，让27B控制器依据完整交互结果改善计划、检查、分支选择和停止时机。
3. **联合RL。**从同一行为版本收集完整轨迹，控制器的动作概率与生成器的随机转移概率共同解释轨迹分布；两侧根据同一终局任务回报更新。更好的规划改变生成器接到的条件，更好的执行改变Agent后续看到的证据。

SFT给出可用的初始合作方式，RL根据实际执行效果调整合作。主RL损失只含policy gradient与固定SFT reference的KL；不再每轮混入多种监督回放和额外校准器。模型、目标和验证之间保持直接关系。

0.3 本版的关键决定

- 模型更换依据实际config、权重shape和运行代码核验。Qwen3.8-27B沿用Qwen3_5ForConditionalGeneration，不是把4B结构等比例放大；9B的文本维度、投影、参数和attention后端全部重算。
- 两侧SFT后均**保留policy LoRA，复制一份冻结reference，RL继续更新policy**。没有合并再量化，也没有新建零B的RL适配器。
- FINISH(image_id)统一交付动作。是否完成由实际图像决定，删除旧版ACCEPT/STOP奖励不对称造成的弱支配。
- 保留四个有直接训练含义的设计：同状态修复/回退/结束监督、阶段均衡SFT、根计划与后续执行的分层信用、四个扩散时间段的带权重放。
- 主工作集为512^2、两个活跃区域和两个图像参考；DAG可表达更多实体，必要时分步骤执行。27B最大输入6144、动作1024 token。768^2属于有独立资源门的扩展配置。

后文给出完整实现契约；§21集中说明与开源实现的差异，§23区分已经完成的验证和目标机器上的验收。方案的重点是把闭环跑通并检验学习效果，事实核查服务于这一目标。

1. 主配置与模型选择

1.1 唯一主方案

部件	固定选择	可训练内容与理由
Controller	Qwen/Qwen3.8-27B	NF4冻结底座＋语言rank16 LoRA；较强视觉理解、规划与反馈能力由同一模型承担
Renderer	FLUX.2-klein-base-9B	BF16冻结底座＋rank16 DiT LoRA；未蒸馏flow底座、生成与多参考编辑共用接口
Public checker / terminal judge	Qwen3-VL-32B-Instruct	NF4、完全冻结；另加几何、检测和特征证据，避免小判据成为主要能力限制
Offline teacher	冻结27B快照	只读目标动作当时的AgentView；复用Actor硬件，提案须经编译与真实执行筛选
Klein条件编码	同一9B快照内Qwen3-8B＋VAE	完全冻结；文本BF16、VAE FP32；与27B控制器分开加载
主训练采样器	50步、CFG4、全步Flow-SDE、η=.3	正方差转移提供明确的图像策略score；20/28步需通过 § 12质量门
每回合预算	10动作、3 renders、2 INSPECT、2 READ_NODES	可完成初次生成、两次修复及必要检查/回退
每联合轮	P6任务、N2根计划、M2后续分支	24条完整轨迹，每次实际render重放4个时间段
更新	每批新轨迹，两侧各一次optimizer step	同一行为点计算两侧梯度；仅适配器梯度在各自服务器归约

用户给出了27B容量要求，未提供确切checkpoint名称。本版根据公开实现自主选择Qwen3.8-27B；同时对比了3.5/3.6的配置，确认三者主要结构相同。官方模型卡将规划、环境反馈和长期Agent能力作为后继改进方向，作为选型依据；本项目是否获益由相同底座的任务实验决定，不把发布者成绩当成本项目实测。S1

9B仍是可在单5090上训练适配器的工作集：DiT权重16.91GiB，policy/reference及优化器静态状态约0.60GiB，冻结编码器另放A2。它与4B使用同一类packed latent和控制入口，升级主要是执行能力与容量，而非引入另一套系统。S2 S24

1.2 量化、许可与采用范围

NF4降低的是冻结权重存储与算术精度，模型的27B结构和上下文能力保持完整；量化后的质量仍须单独比较。主训练、采样、reference和正式评测始终使用同一份序列化NF4底座，不把BF16与NF4交替当作同一个策略。

9B官方权重采用FLUX Non-Commercial License，下载需要账户同意模型条件。本次公开元数据、官方BFL架构和Diffusers转换代码能够相互核对；受控文件返回401时未绕过。本规范据此完成设计，实施时在有权下载后再对实际config、键集合与shape做strict检查。这是研究使用的模型准入步骤，不需要改变课题方向。S2 S24

主算法对比统一使用27B＋9B；旧4B只用于额外容量消融。这样能区分模型升级收益与DAG、SFT、RL及联合学习各自的收益。

2. 系统组成、固定版本与复用方式

2.1 模块边界

每轮闭环为：**构造可见状态 → Agent采样动作 → 类型校验与DAG revision → 条件编译及必要执行 → 保存图像和证据 → 再决策**。学习侧消费实际行为记录，不能从最终图反推历史。

模块	输入 → 输出	责任
Task / CheckSpec builder	请求、用户图像 → 公开任务与固定公开检查	训练和部署同一函数；私有评测标准独立保存
TypedDag / BranchManager	typed patch、工件引用 → 不可变revision	执行依赖、观察来源、实体绑定、分支与重算闭包
ArtifactStore	RGB、mask、tensor、metadata → 内容地址	值身份、来源身份、坐标、跨机位置及缓存
AgentViewBuilder	revision、已见证据、预算 → 6144-token内多模态视图	保留原始source与当前图，分页读取其余公开节点
27B Actor worker	视图 → 原始动作token、概率、动作	规划、控制选择、定位、修订、回退与交付
ConditionCompiler	计划、区域、绑定 → ConditionBundle	构造真正进入9B的文本、latent、mask与IDs

模块	输入 → 输出	责任
Frozen encoder service	文本/RGB → 冻结embedding/latent; latent→RGB	A2运行Qwen3-8B与VAE，按版本缓存
9B renderer worker	bundle、seed、policy版本 → FP32轨迹与图像	同一CFG velocity入口用于采样和学习
Observer / Reward services	图像＋公开/私有标准 → 各自结果	权重可共享；输入、DTO、缓存和响应通道分开
TrajectoryStore	所有动作、调用、结果 → 完整分层batch	保存失败、回退和被放弃的实际render
JointLearner	batch → θ/φ梯度与新版本	分层score、固定reference KL、双侧一致提交

2.2 锁定版本

对象	固定版本
Qwen3.8-27B	1d4bf0f2ff6012fd82039f2fa52739d0dd7c60c0
FLUX.2-klein-base-9B全套组件	32773329fbe7e81a90ef971740e8ba4b0364ecf3
Qwen3-VL-32B-Instruct	1e6810acf5d8ebd189b4e75590877b64358e454c
Transformers5.12.1	ddb849abe009d1089e6c691bfc897f27211c663c，加§6所述最小FP32 cache修复
PEFT0.20.0	a5526d27a9d47d1e8264d5e1b1f96c0fdc79464e
Diffusers	275869dcae4ebcfee6a80253fdabc56033335020
bitsandbytes0.50.2	08a9956b939857ae2c4fbd56753960cc370fa7cf
flash-linear-attention0.6.0	413ad2c655ece57b94bc9ddc51fdbd43cf09d984
causal-conv1d1.7.0	cd81f0413cad2fc1e6f17e785ac39f59aae690cd
主环境	Python3.12、PyTorch2.13.0+cu130、torchvision0.28.0

每个服务保存自己的wheel hash、CUDA/驱动、实际kernel、模型/adapter/量化/processor hash。控制器全attention先用原生SDPA，GDN采用已锁FLA；9B显式选择Diffusers _native_efficient。不开启torch.compile、跨动作KV复用或推理引擎替换。代码支持与目标GPU上运行是两项证据，先过§19集中验收再训练。S3 S5 S17 S25 S26

2.3 具体从哪里复用

开源实现	采用的实际部分	本项目需要补齐
Tencent UniRL	Klein配置驱动worker、条件DTO、逐步轨迹、SFT/RL组织	Qwen3_5 NF4 worker、DAG多轮交互、显式mask/IDs、FP32链、分层优势和一致发布
Diffusers / BFL	9B Transformer、Qwen3文本编码、VAE/BN、img2img LoRA训练、efficient attention	区域编译、target/source独立mask、多参考角色、完整Gaussian重放
RePlan	区域文本独立编码与空间可见域	独立source/target frame、引用版本、正确两支CFG和可审计候选
Flow-GRPO	Flow-SDE与采样后重算思路	实际转移方差的KL、分层任务回报、固定分母、全轨迹score
TRL RLOO	同提示独立采样、leave-one-out与mask实现参考	自有根/后缀分组及双模型梯度；其现成trainer不等同本目标
ComfyUI	就绪队列、带槽名的依赖签名与缓存思路	不可变历史、观察边、分支隔离；训练replay独立于inference_mode执行器
UMM-Reflection	更新阶段与事务状态组织	两侧adapter/optimizer/RNG的PREPARED→COMMITTED发布

复用到函数的来源与修复见§21–22。这里不把多个trainer串接后称为联合训练；两侧的采样分布、score、reference、归约和版本一致性由§11–15统一定义。

3. 任务、身份、工件与 DAG 的完整语义

3.1 四个对象与公开/私有双通道

对象	来源与可修改性	Agent 可见性
UserRequest	不可变原文、原始源图、用户明确提供的参考/布局	始终可见
PlanRequirement	Agent 对原文的分解、实体、控制和依赖，可 patch	可见、可修改
CheckSpec	冻结分解器仅根据 UserRequest 产生；回合内固定	根 PLAN 后可见，作为部署时也能取得的检查依据
EvaluationSpec	独立核验的评分要求；回合内冻结	**始终不进入 Agent 输入或公开 DAG**

根 PLAN 只读原始请求与允许的用户图像。冻结分解器可预计算 CheckSpec，首次合法 PLAN 后披露公开检查项与源图检查证据。训练、开发、正式 benchmark、实际部署使用同一个函数、提示、processor、解码设置和缓存规则。外部分解器可能漏项或产生错误要求，不能把它当作金标准；它的覆盖率和误报率单独评估。

分解器复用 A#3 的冻结 Qwen3-VL-32B NF4，do_sample=False，输入≤8192、输出≤1024 token。准入同时检查分解器自己的完整必需输入；超过8192使用独立较大上下文配置，不截断原文。固定任务提示要求：只依据原文和用户附件拆解可检查要求；每项引用实际原文字符区间；分开实体数量、属性、空间关系、文字、参考外观；不引入未要求的对象、背景或风格；对模糊项保留 unknown。原文先 NFC 规范化并固定 hash，span 用该字符串的 Unicode code-point 半开区间 [start,end)，同时保存原始文字。schema 校验要确认 span 的引用文本完全一致。

解析失败可用相同公开输入、固定格式纠正提示重试一次；仍失败时使用一项“整体是否符合原始请求”的公开检查，并标记 decomposition_fallback=true。不能拿 EvaluationSpec 补齐漏项。超过12项的公开要求按每批12项分块执行和分页展示，保留全部项；资源账按实际项数增加。主训练任务的私有要求起始上限为12，超容量任务用明确扩大配置，绝不在正式 benchmark 静默删要求。

```
PublicTask:
 task_id, split_id, family_id, source_dataset, license_record
 user_request{text, spans, source_image?, appearance_images[], user_controls?}
 canvas{height=512,width=512}, task_mode{generate|edit}
 check_spec{version, extractor_version, atoms[], fallback}
 limits{max_entities=16,max_active_regions=2,check_atoms_per_batch=12}

PublicCheckAtom:
 check_id, origin{request|source_inference}, raw_span_ids[]
 predicate, entity_refs[], expected_value, public_reference_ids[], confidence

PrivateEvaluation:
 private_task_key, eval_atoms[], original_protected_mask?
 source_baseline_observations, annotation_provenance, evaluator_version

PrivateEvalAtom:
 eval_id, raw_span, predicate, expected_value, checker_route, threshold, mandatory
```

check_id 与 eval_id 使用独立命名空间，无相互可见映射。隐藏 target、benchmark vqa_list、标准答案、注入原因和 private protected mask 均在评分侧。评分进程可以通过内部 task key 关联图像，Agent 只持有 PublicTask 和公开工件。保护区域若用户确实提供，则用户版本可见；内部评测额外标注不能借此变成控制输入。

默认自动检查只评固定 CheckSpec，避免 Agent 通过修改计划来删检查项。Agent 自己的计划一致性检查可通过 INSPECT(kind=plan_consistency)请求，结果标记 origin=plan，不能覆盖基础 CheckSpec，也不决定最终奖励。错误定位可比较原文、当前计划和公开视觉证据；“漏项”是公开检查器的发现，不是金标准直接给答案。

独立 EvaluationSpec 表示独立标注的要求，不保证视觉判据永不出错。每项仍按 §9 校准与 known/unknown 规则评价。私有评分只在 episode 结束后对**实际交付图**计算；原始 source 可提前在私有通道评分一次以建立回归基线。中间图的隐藏评分仅用于离线 SFT 筛选或终止后的诊断，不能改变已执行回合。

SFT 可以用私有评分事后选择动作，但**目标动作也只能引用已经公开的节点、check ID 或原文 span**。数据生成教师读公开状态；隐藏原子不能通过教师提示、候选排名、日志、分页、缓存描述或“错误说明”泄漏。空要求、明确矛盾任务在任务构造时隔离并记录，不能按生成成败事后筛训练组。

3.2 图定义

$$G = (V, E_d \cup E_o).$$

V 包含请求、计划项、实体绑定、控制工件、操作、图像/张量工件、观察和决策的**不可变版本**。E_d 表示实际消费的计算输入；E_o 表示一次决策或诊断实际读过的观察。场景关系 left_of、wearing、same_identity 是节点内容，不直接当作执行边。

例如，控制器看过整张图再修改左侧杯子，该决策的观察依赖必须指向整图版本。仅保存 crop 依赖，会错误允许“换了整图还沿用旧决策”。

NodeSpec:
node_version_id, logical_node_id, episode_id, branch_id
kind, schema_version, operation, typed_parameters
inputs[(slot_name,index,artifact_value_id,producer_version_id)]
data_parents[], observation_parents[]
request_span_ids[], plan_requirement_ids[], entity_ids[]
frame_ids[], version_vector, rng_key?

NodeEvent:
event_seq, node_version_id, event_type, timestamp
output_artifact_ids[], error_code?, evidence_ids[]

BranchManifest:
branch_id, revision_id, parent_revision_id
bindings{logical_node_id:node_version_id}
selected_image_id, selected_plan_revision, active_control_set_id

状态机为 CREATED → READY → RUNNING → SUCCEEDED/FAILED；缓存命中记录 CACHE_HIT → SUCCEEDED。重试创建新的 attempt 事件，不改写旧输出。取消记录 CANCELLED。STALE 是“某 revision 不能复用某输出”的视图属性，不是全局删除节点。

执行图中新决策只读取已完成版本；操作与输出在拓扑顺序中创建。导入的计划依赖先做类型检查和 SCC 检查，拒绝自环与多节点环；合法后再展开执行节点。控制器回合通过追加版本展开，整个历史保持无环。

3.3 值身份、来源身份与缓存

$$v(A) = \text{SHA256}(\text{type,shape,dtype,frame,payload}),$$
$$p(A) = \text{SHA256}(\text{producer,ordered slots,stamps}).$$

规范 payload：RGB 使用解码、颜色规范化后的 uint8 HWC 像素，不用 PNG 压缩字节作为像素相同的依据；张量使用连续行主序、明确 little-endian dtype；文本采用 NFC UTF-8；元数据采用排序字段的规范编码，浮点参数固定为有限 float32。NaN/Inf 在写入前拒绝。frame 定义中的缩放、padding 和源尺寸均参与身份。

同值可以有多个来源；缓存按值复用，审计仍保存实际 producer。**输入签名必须包含槽名和列表顺序，不能只把输入 hash 排序。**交换 source 与 appearance 后，条件意义已经改变，即使输入图像集合相同。

$$K_v = H(\text{op,schema,ordered input slots,args, model/adapters,compiler,backend,dtype,RNG}).$$

编码缓存包含 tokenizer、template、提取层、VAE/BN 和几何版本；检查缓存包含图像值身份、requirement、judge 权重、模板、预处理和确定性 seed。render 缓存还包含完整条件、sigma 表、CFG、噪声种子和行为版本。

在线 RL 只跨轨迹共享冻结、确定性的预处理缓存。每个新的随机 render 都有新的作业身份和 RNG 流，不能用另一兄弟轨迹的生成结果代替采样。重试同一个作业时允许幂等取回其已完成结果。训练 replay 必须重新前向并建图，不读取推理 activation 缓存。

3.4 修订与重算

对修改节点集 U 和新 revision 请求的输出集 O：

$$\mathcal{C}(U, O) = \left(U \cup \text{Desc}_{E_d \cup E_o}(U)\right) \cap \text{Anc}^*_{E_d \cup E_o}(O).$$

依次执行：验证 expected_old_version → 创建新节点 → 更新绑定 → 检查图与坐标 → 计算闭包 → 查询缓存 → 拓扑执行 → 对新图检查全部公开 CheckSpec 要求。观察依据变化后的旧决策仅保留为历史，不自动作为新动作

执行。

兄弟分支共享不可变工件，不共享 selected_image、候选队列或预算对象。SELECT 同时恢复历史图及其配套 plan/control revision，下一次编辑明确以选中图为 source。旧分支不会因新分支失败而丢失。

DAG 缓存节省的是编码、几何处理、检查等实际命中的操作。主配置每次修复仍运行完整 DiT；空间 attention 也允许跨层信息传播。记录真实调用量与 FLOPs，不把“局部节点修复”等同于像素严格不变或 DiT 局部计算。

3.5 实体身份绑定

实体 ID 在任务内稳定，例如 entity:0003；修改颜色、位置或外观绑定不会重新编号。每个 reference binding 明确 entity_id、reference_image_id、crop_mask_id、role{appearance|style}、source_frame。匿名检测框先匹配实体，再进入观察。

匹配采用约束 Hungarian assignment。类别不兼容的配对代价为无穷；其余代价为

$$c_{ij} = 0.5(1 - \mathrm{IoU}_{ij}) + 0.5(1 - \cos(f_i, f_j))/2.$$

这里 f 是冻结 DINOv2 crop 特征；无历史位置时仅使用外观项并归一化权重。加入代价 0.7 的 dummy 节点，未匹配或第一/第二选择差小于 0.1 时标记 identity_unknown。这些阈值在开发集校准后冻结。移动操作使位置变化合法，故匹配可取消 IoU 项，但必须由明确的移动指令触发并记录。此匹配是诊断证据；身份最终要求仍由独立参考、语义判据和人评核验。

4. 动作协议、状态机与错误定位

4.1 统一动作

每次采样一个 JSON 对象，允许含不超过 40 token 的简短 reason；它也是实际采样 token，RL 不删除其概率。协议版本固定，禁止调用任意 Python、任意 URL 或未登记工具。

动作	必填输入	执行语义
PLAN	原文 span、实体、子任务、依赖、全局文本、初始控制绑定	创建计划与控制 revision，不生成图像
RENDER	control_set_id,expected_revision	编译并生成一次，检查公开 CheckSpec，选中新图
DRAFT_REPAIR	source_image_id,evidence_ids,suspect_node_ids,patch_ops,instruction	构造并校验 1–3 个不同候选，不生成图像
APPLY	candidate_id,expected_revision	提交候选 revision，执行一次 render，检查并选中新图
INSPECT	image_id,kind,entity_id/region	crop、检测、分割、公开要求重检或计划一致性；占视觉检查预算
READ_NODES	node_ids[]或公开page_cursor	只读取公开 DAG/CheckSpec 投影；每次≤16记录且≤1024 token，回合最多2次；仍占1个动作
SELECT	历史 image_id	原子切换图像与配套 manifest，后续可继续编辑
FINISH	可选 image_id,reason	省略image_id交付selected；字符串交付该合法历史图；显式null表示无图终止

FINISH 必须区分字段缺省与显式null：解析器保留字段存在性，不能把二者都转换为同一个None默认值。根状态仍须先提出计划；无图放弃由合法PLAN后的FINISH(null)表达。

初始状态唯一合法动作是 PLAN。不采用 grammar 强行保证成功：其他 root 动作或非法 JSON 被记录为一次策略非法，fork 后各分支可通过 PLAN 恢复。根动作只采一次，计入 10 步上限；其确定性效果、revision、预算和非法计数一起复制到各后缀。首次图像生成在 fork 之后。编辑任务可在合法 PLAN 后直接 FINISH，交付已存在的源图。

PLAN 只在没有有效计划时合法；已有计划通过 typed patch 修订。动作只能引用本分支当前或此前已披露、仍合法的 ID，共同前缀只读工件除外，不允许跨兄弟分支访问。视图提供被省略节点的 ID 目录与分页 cursor，READ_NODES 据此读取，不让模型猜未见 ID。终止器不按隐藏reward自动挑选“最好图”。分页

cursor绑定episode/branch/revision/collection_kind/offset/projection_hash，CheckSpec原子也属于可分页公开投影。过期返回STALE_CURSOR和当前合法cursor，消耗本次动作/read但不计策略非法；不静默切到另一revision。单条记录超页预算返回摘要与公开工件引用，后续按字段读取仍计read；预算内未读完可FINISH并承认未完成，不能用隐藏评分补齐。

编辑任务的原始源图在初始检查后可作为候选。零 render 但交付正确源图是合法行为；纯生成没有图像可交付时为失败。这样可以训练正确停止与回退，而不会人为要求每个回合必须生成。

源图的公开检查可以提前计算，但根视图只给原始请求和图像；成功执行PLAN后才披露 CheckSpec 及其检查证据。非法根后的恢复PLAN同样遵守此规则。源图私有评分永远不披露。

4.2 Typed patch 与候选编译

```
PatchOperation:
 target_logical_node_id, expected_old_version_id
 op{add|replace|retire}, field_path, typed_value_or_artifact_id

RepairCandidate:
 candidate_id, source_image_id, parent_revision
 patch_operations[], scope{local|expanded|global|custom|retry}
 changed_nodes[], recompute_nodes[], compiled_condition_hash
 required_render_calls=1, validation_result
```

允许修改计划解释、数量/属性、依赖、布局、区域文本、参考绑定和源图绑定。禁止修改原始请求、固定公开 CheckSpec、独立评分标准、原始保护区域、历史图像 bytes、评价器或预算。旧版本不匹配时返回 STALE_PATCH，不替控制器猜测新目标。

add 要求目标尚不存在、expected_old_version_id=null；replace/retire 必须匹配当前版本。普通编辑的 source 在编译时晚绑定为当前 selected；恢复历史 manifest 后，不能沿用生成该历史图时的旧 source。DRAFT_REPAIR.source_image_id 必须等于 selected，编辑别的历史图先 SELECT。候选保存该图和 manifest hash，APPLY 再验证二者未变。明确的 retry 例外：复制选中图 producer 的完整历史 bundle、只换 seed，记录其实际 source；它是重采原操作，不冒充对当前图继续编辑。

默认候选生成规则：

1. local：执行目标节点 patch，仅修改对应区域控制；其余实体和要求不变。
2. expanded：在 local 基础上纳入共享实体或与目标区域 IoU>0.2 的控制区域，并将目标作用 mask 外扩 2 个 latent patch，即 32 像素；保留相邻区域原本的文本，不将所有对象统一改写成同一指令。
3. global：将经过修订的完整目标描述编译成全局条件，取消局部文本分区，但保留原始全部要求和明确参考绑定。

source 与 target 作用区域分别计算；对象移动时不能用 target mask 覆盖 source mask。目标区域缺失时先用可靠检测证据建区域；仍无法定位则只生成 global/custom。计划级错误允许直接修祖先节点，不先强制尝试局部图像编辑。retry 明确保持条件相同、重新采样；它与条件修订分开记账。

候选按编译后的完整条件去重；不足三个就返回实际数量。candidate 描述包含真实变化、预计重算操作与成本，不包含执行后的图像或奖励。控制器负责选择，编译器不代替它择优。

自动扩展若超过两个活跃区域，返回该候选的CAPACITY_EXCEEDED原因并保留其他合法候选，不合并或丢弃实体。控制器可选择global，或明确分步提交custom patch；用户要求始终完整保留。自动候选验证失败不额外计策略非法，只有原始动作本身违反合约才计数。

4.3 错误节点定位

合约错误返回字段生产节点；公开检查器依据原文发现的漏项指向计划祖先；错误参考指向 binding；可靠位置证据指向 layout；条件合法但执行失败时保留 render 与条件节点为多个候选。对失败观察 o，首先计算

$$\mathcal{B}(o) = \mathrm{Anc}_{E_d \cup E_o}(o) \cap V_{\text{mutable}},$$

再按原文 span、实体、frame 与证据收缩候选。图可达性提供候选范围，不自动证明视觉因果。自然失败没有可靠唯一原因时输出候选集合；SFT 不伪造唯一根因标签。

4.4 可见状态与确定性执行

视图含原始请求、当前计划/绑定、相关节点及祖先、最近三条错误、公开 CheckSpec 与证据、候选摘要、预算。最多四张图，顺序为原始source（编辑任务必留）、当前图、主动crop、外观参考；相同像素工件只编码一次并保留多个角色标签。生成任务没有source槽。Qwen3.8 按每张最多 256 个视觉 token 处理；512×512 在其 patch16、merge2 结构下是 256 token，448×448 是 196，合并后每个视觉token宽5120；本控制器没有DeepStack注入。S1 S3

总输入超过6144时依次删除最旧错误、冗余摘要、无关节点，最后可去掉可选crop；原始请求、原始source、当前图、当前动作必要字段和完整图像块不得截断。任务准入先用真实tokenizer计算原文、最大必留图像、1024token计划与必留字段的最坏视图，超限任务在采样前进入独立较大上下文配置。在线若仍因实现错误出现VIEW_OVERFLOW，暂停并保留完整组，修复后从同一行为版本与RNG恢复；不能中途换上下文、丢该分支或伪造策略失败。较大上下文仅在新任务配置/stage启用并重新做显存验收。保存 processor 输出和图像 hash，禁止事后用新 DAG 重建旧视图。

设置 processor max_pixels 为 $256(16\cdot 2)^2 = 262144$。静态图的实际 pixel_values 是 [P,1536] float32，其中 $P = \sum \text{prod}(\text{image_grid_thw})$，1536=3×2×16×16；512² 图的 grid 为 [1,32,32]，经 merge 得 256 个视觉 token。它不是 VAE 的 BCHW 张量。以 processor 的实际 grid 核对数量，冻结 resize/normalization 设置。S3

```
root = sample_validate_and_execute_root_PLAN()  # turn 0; invalid => count 1
for branch in fork_independent_suffixes(root.state, M=2):
  run_suffix(branch, first_turn=1, last_turn=9)

# run_suffix is executed independently for each branch:
for turn in range(1, 10):
  obs = build_view(revision, evidence, budget)
  raw = policy.sample(obs, max_new_tokens=1024)
  record_raw_tokens_and_behavior(raw, obs)
  action, error = validate(raw, revision, budget)
  if error:
    record_error(error)  # every sampled action costs one turn
    if error.is_policy_invalid:
      invalid_count += 1
    if invalid_count >= 2:
      return terminal_protocol_failure(-1)
    continue
  if action.kind == "SELECT":
    revision = restore_image_and_manifest(action.image_id)
  elif action.kind in {"RENDER", "APPLY"}:
    revision = execute_one_render_and_measure(action, revision)
  elif action.kind in {"FINISH"}:
    return finalize(action, revision)
  else:
    revision = execute_nonrender_action(action, revision)
return finalize_budget_exhausted(revision.selected_image_id)
```

每个采样动作消耗一步；render 预算仅在实际接受并发起作业时增加。自动公开检查是 render 的固定组成，额外 INSPECT 与 READ_NODES 分别计数。render/inspect/read 预算耗尽时拒绝相应动作，消耗一步但不额外罚款；仍允许 SELECT、FINISH。10 步耗尽返回当前选中图，有图按正常奖励计算，无图 −1。有限预算保证闭合。

非法 JSON、未知 ID、越界/退化几何和非法状态计为策略非法；首次可恢复，第二次协议失败终止。文本超出编码容量属于明确的 TEXT_TOO_LONG，同样计非法，禁止静默截断。服务异常、OOM、版本不匹配不伪装成非法动作；处理见 § 16。

每个Actor worker同一时刻执行一个完整动作请求；模型内部RoPE状态与一次动作内cache属于该请求，不能在多个分支之间交错token。每动作从公开视图重新prefill，缓存仅加速该动作的自回归。具体27B模板、EOS、FP32 recurrent state与reference切换见 § 6和 § 11。

5. 多模态接口与几何约定

5.1 工件与坐标

工件	形状 / dtype	语义
RGB 持久图像	[H,W,3] uint8	sRGB，0–255，EXIF 旋转先应用，alpha 合成到RGB(128,128,128)背景
模型图像	[B,3,H,W] float32	0–1；进入 VAE 前转换为 −1–1
像素 mask	[H,W] float32	0–1，明确所属图、frame、用途；soft 与 binary 不混写
bbox	[4] float32	归一化半开 xyxy；有限且满足 0≤x0<x1≤1、0≤y0<y1≤1
几何变换	[3,3] float64	原图到 canvas 的齐次变换及逆变换
packed latent	[B,L,128]	状态 FP32，参考缓存 BF16；角色由 slot 指定
文本 embedding	[B,Ltext,12288] bfloat16	固定编码器、模板、层与 padding 协议

等比 letterbox：先取 $s = \min(512/W_0, 512/H_0)$，令 $W' = \mathrm{round}(sW_0)$、$H' = \mathrm{round}(sH_0)$，记录实际 $s_x = W'/W_0, s_y = H'/H_0$ 与居中整数 padding (p_x, p_y)。变换为

$$A = \begin{bmatrix} s_x & 0 & p_x \\ 0 & s_y & p_y \\ 0 & 0 & 1 \end{bmatrix}.$$

RGB 用固定 Lanczos；binary mask 用 nearest；soft mask 用 area/bilinear 并记录算法。源图与配对 target 必须共享注册变换；原始尺寸或裁剪不同，先验证配准，不能各自 letterbox 后直接计算保留损失。无法配准的对不进入像素保护监督。appearance 独立变换，不假定和输出像素对应。

所有padding同为RGB(128,128,128)。canvas几何采用图像边界为整数的坐标，像素中心为 $(x + 0.5, y + 0.5)$；外部关键点若以首像素中心为0，先加0.5再应用变换。bbox保持半开边界，mask变换按像素中心采样，来源坐标约定写入frame。

RegionControl 明确 target_mask、source_mask、entity_ids、region_text、appearance_bindings。新增对象允许 source mask 为空；移动对象两侧位置不同；删除对象的 target 编辑区覆盖原位置。空指针和全零 mask 含义不同：前者表示此侧不适用，后者在声明有区域时是错误。

5.2 VAE 与 latent

对 512×512 图像：

$$\begin{aligned} z_v &= \mathrm{mode}\, q_{\mathrm{VAE}}(z \mid 2I - 1) \in \mathbb{R}^{B\times 32\times 64\times 64}, \\ z_p &= \mathrm{patchify}_{2\times 2}(z_v) \in \mathbb{R}^{B\times 128\times 32\times 32}, \\ z &= (z_p - \mu_{\mathrm{BN}})/\sqrt{v_{\mathrm{BN}} + \epsilon_{\mathrm{BN}}}, \\ Z &= \mathrm{pack}(z) \in \mathbb{R}^{B\times 1024\times 128}. \end{aligned}$$

patchify 的通道顺序为 $c' = 4c + 2\delta_h + \delta_w$；pack 按行主序遍历空间。BN mean/variance/epsilon 来自同一 checkpoint，全部冻结。VAE 编解码 FP32，使用 posterior mode；目标、source、appearance 共享同一个编码核心，包装分别返回 canonical target 或带角色的 packed reference。解码严格做 unpack、反白化、unpatchify、VAE decode。S4 S6

缺失 BN 统计、通道错误或 shape 不符直接阻止该模型配置启动。验证包括 patchify/pack 的精确逆变换、编码与官方单图路径的数值比较、训练前后 BN buffer 不变。

5.3 文本、位置 IDs 与 bundle

全局文本一块，最多两个区域块，每块独立使用 Klein 配套 Qwen3 模板，固定长度 512，由同一9B快照内的Qwen3-8B文本编码器取 hidden states 9、18、27 拼接成 12288 维；保持官方 padding embedding，不置零。先检查模板化后的长度，不能依赖 tokenizer 静默 truncation。S4

令区域数为 n_r，参考总数为 $n_c \in \{0,1,2\}$，其中 source 也计作参考段：

$$L_t = 512(1+n_r), \quad L = 1024, \quad S = L_t + L(1+n_c) \le 4608.$$

联合 attention 顺序为 [全局文本,区域文本 | target噪声 | source?,appearance?]。图像段按实际输入列表依次编号，target 为 0，后续第 j 段为 $j \ge 1$：

$$\text{imgid}(j,r,c) = (10j, r, c, 0), \qquad \text{txtid}(i,\ell) = (0,0,0,\ell).$$

每个文本块 ℓ 从 0 重启，这是区域编译设计；参考图的时间轴按官方列表次序。无 source、只有 appearance 时它是第一参考，time=10；source+appearance 时分别为 10、20。角色另存，不能靠 time 猜角色。

```
ConditionBundle:
 bundle_id, canvas_hw, region_count, num_target_tokens=1024
 positive_embeds[B,Lt,12288], negative_embeds[B,Lt,12288]?
 text_ids[Lt,4], image_ids[(1+nc)*1024,4]
 reference_tokens[B,nc*1024,128]
 token_span_table, source_membership, target_membership, appearance_membership
 positive_mask[B,1,S,S], negative_mask[B,1,S,S]
 cfg_scale, sigma_table_id, attn_impl, layout_signature
 artifact_bindings, model_versions, compiler_version
```

IDs 使用 int64 保存，按模型入口要求转换；reference/text 前向 BF16；mask 为 bool、True 表示允许访问。不同任务可并批的条件是布局签名相同：网格、IDs、段长度和顺序完全一致；embedding 和 mask 可逐样本不同。初版 microbatch=1，不依赖跨布局 batching。

5.4 区域 attention

对每个区域分别在 source 和 target 网格栅格化：

$$\rho_{ip} = \frac{1}{256} \sum_{(x,y)\in P_p} m_i(x,y), \qquad b_{ip} = \mathbf{1}[\rho_{ip} \ge 0.25].$$

正面积区域若无 patch 达阈值，保留覆盖率最大的 patch，并列取最小索引，记录 fallback；真空区域拒绝。重叠区域采用多标签 OR，不允许后写覆盖前写。

令 G, T_i, Y, C, A_j 分别为全局文本、区域文本、target、source、appearance；Y_i, C_i 用各自 mask 确定；B_j 为参考绑定区域：

参考内实体的 crop_mask_id 也经过该参考自己的变换与池化，产生 token 子集 $A_{j,i} \subseteq A_j$。下表中的区域参考连接只连接这些子集；参考 token 只有属于该实体子集时才连接对应区域。reference_scope=global 则连接整段参考；没有活跃区域时，普通全局 reference 也采用该显式 scope，避免参考完全断开。global 修复若取消区域，必须同时记录参考 scope 的转换。

Query	可读取的 Key
G	$G \cup Y \cup C$，加 scope 为 global 的参考
T_i	$T_i \cup Y_i \cup C_i \cup \bigcup_{j:i\in B_j} A_{j,i}$
$y_p \in Y$	$G \cup Y \cup C$，加全部 global reference，以及覆盖 target 位置的区域文本及其参考
$c_p \in C$	$G \cup Y \cup C$，加全部 global reference，以及覆盖 source 位置的区域文本及其参考
$a_p \in A_j$	$A_j \cup G$，加该 token 所属实体的 T_i, Y_i, C_i；global reference 加全部视觉段

未列边为 False，每行必须非空。该断言保证接口语义；不声称所有 PyTorch 后端对空行都会产生 NaN。mask

不按 head 显式复制，最大单样本 bool 矩阵为 20.25 MiB。

原生 Flux2 processor 消费 attention_mask。启动时对**每个** attention processor 检查参数签名；未知 kwarg 在本封装直接报错，因为库可能只 warning 并丢弃。不能将 RePlan 的 flex_block_mask 塞给原生 processor 后假定生效。S2 S7

5.5 唯一 velocity 入口与 CFG

负文本由同一编码器的空字符串块组成，与正支具有相同长度、IDs、布局、source/reference 和 mask。它是“给定空间与图像条件下的文本无条件分支”。

$$v_\phi^{\text{cfg}} = w v_\phi^{+} + (1-w) v_\phi^{-}, \qquad w = 4.$$

predict_velocity(bundle,z,sigma,adapter) 在采样、reference 和 replay 中复用：拼接 noisy target 与 reference tokens；调用 Transformer；只取前 1024 个输出 token。模型入口传 σ，其内部再乘 1000；guidance=None，并断言 checkpoint 的 guidance_embeds=false。正负分支均对当前 LoRA 求导，负支系数为 −3；CFG>1而缺负文本、mask或匹配IDs时立即报错，不能静默退成单支。内存实现见 §14。S2 S4

SFT 使用单支，CFG=1；不把混合 CFG velocity 当普通 flow target。SFT 中 10% 样本将整组文本换为空块，保持布局和参考不变。SFT 的连续时间采样与 rollout 的离散 sigma 表不同，这是有意的训练设计。

5.6 条件编译后的不变量

一次执行的完整条件是bundle中的张量及其来源，而不是一段重新生成的描述。layout改变会改变target membership和attention mask；reference绑定改变会改变角色段与对应可见域；原图更换会改变source latent和source frame。这些变化都进入bundle hash。用户意图、已执行控制和图像证据由DAG关联，控制器据此修订具体节点。区域mask限制信息可见域，**不保证区域外像素严格不变**；保持质量由source条件、监督损失与终局保护指标共同学习。用户明确要求像素级锁定的任务另用显式合成算子配置，不与本默认生成器输出混报。

6. 可训练参数、27B量化适配与参考模型

记控制器可训练LoRA为θ，生成器可训练LoRA为ϕ，冻结判据为ω。所有基座、视觉塔、条件编码器、VAE与判据不更新；两侧policy各有一份固定SFT reference。下面给出完整模块、精度、状态与梯度边界。

6.1 不能从4B简单乘倍数的结构事实

Qwen3.8-27B：64层，按 [linear,linear,linear,full] ×16 排列；隐藏宽度5120，FFN17408，词表248320。48个GatedDeltaNet块、16个全注意力块。全attention有24个Q头、4个KV头，显式head_dim256，不能用5120/24推导head_dim。线性块有16个QK头、48个V头，每头128维。

语言模块	输入→输出	每模型数量	是否量化	是否LoRA
full q_proj	5120→12288	16	NF4	是
full k_proj,v_proj	5120→1024	各16	NF4	是
full o_proj	6144→5120	16	NF4	是
linear in_proj_qkv	5120→10240	48	NF4	是
linear in_proj_z	5120→6144	48	NF4	是
linear in_proj_a,in_proj_b	5120→48	各48	BF16	是
linear out_proj	6144→5120	48	NF4	是
MLP gate_proj,up_proj	5120→17408	各64	NF4	是
MLP down_proj	17408→5120	64	NF4	是

全attention的q_proj输出要分成Q与输出门，各6144维；门是sigmoid。GDN的z门是SiLU，b是sigmoid，a经softplus与exp(A_log)构成负衰减。新config里 output_gate_type="swish" 不应被误读成“把全attention sigmoid换成SiLU”：固定HF源码的 Qwen3_5Attention.forward 和 Qwen3_5RMSNormGated.forward 已明确给出两种不同门；当前main同样如此。这里直接复用官方forward，不自行解释字段改算子。

固定源码：GDN类371–557、full attention645–718、RMSNormGated187–203。

6.2 精确参数及LoRA覆盖

我通过 HTTP Range 只取每个safetensors文件的8字节长度和JSON头，解析所有1199个权重shape，并核对索引键集合相同。结果：

量	实际元数据值
完整发布checkpoint参数	27,781,427,952
其中MTP权重	424,699,392
本方案模型驻留参数，不实例化MTP	27,356,728,560
视觉塔（含merger）	460,730,096
token embedding	1,271,398,400
lm_head，独立不共享	1,271,398,400
被NF4转换的大Linear	400个，24,326,963,200参数
其他非量化参数	3,029,765,360
LoRA目标	496个Linear
rank16时每个adapter参数	116,727,808

MTP不计驻留并不是自己删模型分支：固定 Qwen3_5ForConditionalGeneration.__init__ 仅创建model和lm_head；Qwen3_5PreTrainedModel._keys_to_ignore_on_load_unexpected=[r"^mtp.*"] 明确忽略这组权重。见812–824、1709–1720。仍保存完整上游下载校验，不将MTP静默当作自己训练的组件。

LoRA用rank16、alpha32、dropout0、biasnone，所有语言块的上述投影覆盖；视觉塔/merger、embedding、lm_head、norm、conv1d、A_log、dt_bias冻结。

对线性映射 $W \in \mathbb{R}^{d_o \times d_i}$，单adapter参数为 $r(d_i + d_o)$。因此：

$$N_{\text{linear},16} = 16\{15360 + 11264 + 5168 + 5168 + 11264 + 3(22528)\} = 1,852,928,$$
$$N_{\text{full},16} = 16\{17408 + 6144 + 6144 + 11264 + 3(22528)\} = 1,736,704,$$
$$N_{\text{adapter}} = 48N_{\text{linear},16} + 16N_{\text{full},16} = 116,727,808.$$

PEFT目标正则采用真实模块全名：

```
^model\.language_model\.layers\.\d+\.(?:self_attn\.(?:q_proj|k_proj|v_proj|o_proj)|linear_attn\.(?:in_proj_qkv|in_proj_z|in_proj_b|in_proj_a|
↪  out_proj)|mlp\.(?:gate_proj|up_proj|down_proj))$
```

启动时根据实例化模型枚举，断言目标集合恰好496，参数数目恰好116,727,808；保存名称/shape清单。量化排除96个小a/b门，并不从LoRA中排除它们。

6.3 主执行路径：A0/A1分别一份完整NF4模型

27B BF16驻留权重约50.956GiB，单A6000放不下。主方案采用NF4冻结底座+BF16算术+FP32 adapter，不把27B缩成小模型；两张A6000分别保留完整模型副本，轮换采样与训练，梯度仅在这两张卡之间求和。A2做冻结生成器encoder/VAE，A3做冻结视觉judge/tool，三张5090做DiT。这样没有跨机FSDP，也没有每个生成token跨PCIe all-gather27B权重的负担。

量化配置设计：

```
load_in_4bit=true
bnb_4bit_quant_type="nf4"
bnb_4bit_use_double_quant=true
bnb_4bit_compute_dtype=bfloat16
bnb_4bit_quant_storage=uint8
llm_int8_skip_modules=["lm_head","model.visual","in_proj_a","in_proj_b"]
device_map={"": local_cuda_index}
```

llm_int8_skip_modules 虽名字含int8，但固定4bit quantizer确实读取这个字段。具体见4bit quantizer第121–143行、模块匹配函数、Linear4bit替换。

第一次量化后保存一次序列化的NF4底座，保存每个量化tensor和quant_state的hash，两份worker加载这一相同制品；不让每个阶段或每个副本独立重新量化。官方NF4的block64、双量化第二层block256可在functional.py917–948核验。

6.3.1 prepare_model_for_kbit_training的精度处理

固定PEFT会冻结底座，并把所有非Params4bit的FP16/BF16参数转为FP32。不能调完函数就照抄17GiB预算。见other.py151–244。

可执行准备顺序：

1. 单卡加载固定NF4底座，选择官方多模态类 Qwen3_5ForConditionalGeneration，不使用text-only类。
2. prepare_model_for_kbit_training(...,gradient_checkpointing_kwargs={"use_reentrant":False})。
3. 对非量化且冻结的embedding、lm_head、视觉Linear/Conv、语言conv1d和a/b投影恢复BF16；norm、A_log、dt_bias留FP32。**不能对整个模型执行 .to(bfloat16)，不能改Params4bit载荷。**
4. 插入policy adapter，adapter参数为FP32。开启decoder non-reentrant checkpoint；冻结视觉塔在eval/no_grad下提特征。current decoder在train，dropout全部0，replay use_cache=False。
5. 逐参数检查dtype与requires_grad白名单，记录actual allocated/reserved。

这里各norm/A_log/dt_bias总参数806,144，相比全部非量化BF16额外增加约1.54MiB；大embedding/head不再误增约4.74GiB。

6.3.2 梯度并没有被量化切断

模型的一次投影为

$$y = \widehat{W}_0 x + \frac{\alpha}{r} BAx, \qquad \widehat{W}_0 = D(Q_{\text{NF4}}(W_0)).$$

冻结 $\widehat{W}_0$ 只意味不更新量化底座；它仍需为上游激活传递 $\partial L/\partial x$。bitsandbytes的 MatMul4Bit.backward为输入计算反量化矩阵乘法，量化weight梯度为None；PEFT的bnb层将LoRA支路加到base输出。见bnb backward365–386、PEFT bnb forward510–558。因此不能给整个冻结语言底座forward包no_grad，否则前面层LoRA的梯度会消失。

6.4 SFT到RL：复制同rank adapter作为reference

采用同底座单adapter激活：SFT结束保留policy adapter，复制为冻结reference，RL继续更新policy。没有SFT merge、重新量化或新零B adapter。

$$\pi_\theta = \pi(\widehat{W}_0, \theta), \quad \theta_{t=0} = \theta_{\text{SFT}}, \quad \pi_{\text{ref}} = \pi(\widehat{W}_0, \theta_{\text{SFT}}^{\text{frozen}}).$$

接口：

```
get_peft_model(base, lora_config, adapter_name="policy")
SFT完成：保存policy checkpoint
load_adapter(该checkpoint, adapter_name="reference", is_trainable=False)
```

复制后检查每个tensor值相同，但data_ptr/storage不相同；不能reference指向同一tensor再随policy更新。

每个replay microbatch：

1. model.set_adapter("reference", inference_mode=True)；eval()；no_grad算reference logp/KL目标；缓存仅所需值后结束该无梯度计算。
2. model.set_adapter("policy", inference_mode=False)；恢复语言LoRA白名单，视觉保持冻结；current decoder train()、dropout0、use_cacheFalse。
3. 构建当前图，计算该阶段CE或PG/KL，完整backward。
4. 当前图结束后才能切adapter；不能checkpoint重算过程中把active adapter改为reference。

固定API证据：PeftModel.set_adapter1591–1613；BaseTunerLayer.set_adapter1609–1635。set_adapter会改变requires_grad，不能以为只改路由。disable_adapter()返回未SFT底座，不是本方案reference，不能用它代替。

6.5 视觉、tokenizer和动作概率接口

6.5.1 真实processor

preprocessor_config指定 Qwen3VLProcessor + Qwen2VLImageProcessorFast。固定版本没有 processing_qwen3_5.py；直接使用该revision的 AutoProcessor.from_pretrained。

512×512单图：patch16、temporal_patch2、merge2，静态图复制/组装temporal patch后：

```
pixel_values: [1024, 3*2*16*16] = [1024,1536]
image_grid_thw: [1,3], value [1,32,32]
视觉encoder输出: [1024,1152]
merger后: [256,5120]
```

4图则拼接pixel_values为[4096,1536]、grid[4,3]、image placeholder共1024个。视觉特征为冻结tensor，可按image hash+processor+vision hash缓存；宽度5120，不能用v2的2560，也不能送入Klein专用文本encoder。Qwen3.8视觉配置 deepstack_visual_indexes=[]，模型实现只有一次视觉merger注入，**不保存/传递v2 Qwen3-VL的三层DeepStack特征**。见VisionModel1018–1050、multimodal forward1535–1605。

保存并重放 input_ids,attention_mask,mm_token_type_ids,image_grid_thw,pixel_values或冻结视觉特征,prefix_image_positions,position_ids,template参数。mm_token_type_ids图像为1、文本为0；对生成动作追加0。模型有图而缺该字段会抛错；不能从占位符数量“猜”位置。见position IDs1490–1527。生成路径使用text+3D的[4,B,S] position_ids，普通3D图像位置为[3,B,S]；保存实际行为路径产物并检查，禁止跨action借旧rope_deltas。full replay统一使用§11.1.1的prefix槽位装配，防止异常completion视觉token触发原生placeholder计数冲突。

6.5.2 思考与工具模板

Qwen3.8默认thinking+xhigh，且默认保留历史思考。本方案主动作协议显式：

```
enable_thinking=False
preserve_thinking=False
tools=None
add_generation_prompt=True
```

原因：系统训练的是有限预算的可执行规划/修复动作。规划、诊断和证据字段本身承载必要判断；主路径无需再引入长篇自由CoT、另一套计费和输出截断规则。若以后研究thinking budget，可把生成思考token全部纳入动作概率与预算，另设预注册对照；不能默默删除其概率。

官方模板在non-thinking模式添加 <think>\n\n</think>\n\n 固定前缀，它属于输入，不是采样token。传tools会让模板要求XML <tool_call><function=...>；当前协议输出单JSON，因此不传tools，功能schema放固定system prompt。原始输出token必须保留，不先parse/reformat再算logp。

6.5.3 EOS、padding、分布

词表248320。EOS为 [248046,248044]，其中248046是im_end、248044是endoftext；PAD也是248044。SFT目标序列以im_end结束。RL实际采到任一EOS都计入score并终止，padding由真实长度mask确定，不能用 token_id == pad_id 删除真实EOS。

官方generation_config默认top_k20、top_p.95、temperature1。训练若采用全支持categorical，需要显式覆盖 top_k=0,top_p=1,min_p=0,temperature=项目定义值,repetition_penalty=1，不施加未计入score的其他logits processor。采样时保存的logp必须来自**经过相同温度变换后的完整归一化logits**。

SFT、RL、reference使用同一个chat template、image resize、位置、量化底座和kernel manifest。最大动作长度固定1024，输入6144（总7168）；实际训练峰值在§19验收；不能把静态预算当实测。

6.6 Hybrid cache的真实缺陷和最小修复

这是本次换模型必须处理的主要实现缺口，和“论文如何叙述”无关。

6.6.1 固定5.12.1会把recurrent state误存为conv dtype

cache_utils.py917–941 中 LinearAttentionLayer.lazy_initialization 先从conv_states设置self.dtype，然后用这个dtype创建recurrent_states。在BF16模型上，即便FLA返回FP32 final_state，存储时也会copy到BF16；config里的mamba_ssm_dtype没有在此处被读取。

FLA recurrent kernel明确创建FP32 final_state，且其 backward直接NotImplemented。见final_state分配211–215、backward300–306。

最小修复设计：新增 FP32LinearAttentionLayer(LinearAttentionLayer)，仅覆盖lazy_initialization：conv部分调用原父类；recurrent部分断言incoming dtypeFP32，使用 zeros_like(recurrent_states)，设置initialized标志，不传self.dtype。创建 DynamicCache(config=model.config) 后，在第一次prefill前将48个linear层替换为此子类，16个DynamicLayer保持原状。逐层断言conv BF16、recurrent FP32、full KV BF16。

这和上游后来采用的修复一致：上游FP32修复第1189–1195行 使用zeros_like(recurrent_states)。当前cache API已整体改造，本项目不必为这一个修复立即升级整栈。

6.6.2 cache是一次动作内部优化，不是DAG状态

旧cache的linear crop() 是no-op，无法撤销recurrent state，见912–915。因此：每个Agent动作从当前公开视图重新prefill；动作内部用cache加速自回归；动作结束销毁cache。DAG SELECT/rollback改变工件指针与revision，不复用/裁剪旧语言cache。

replay始终完整前缀+动作、past_key_values=None,use_cache=False，走有backward的chunk GDN。不能为了省显存把prefix的状态detach后只反传后半段，那会丢失参数对prefix编码的梯度。默认microbatch1、无sequence packing，也避免packed样本的linear recurrence跨样本串流。

6.6.3 精确概率的一致性验收

“相同权重”仍不能代替采样/重放对照，因为cached decode和full-sequence chunk有不同数值路径。正式训练前，用0/1/2/4图、短/长输入、两个EOS等固定case：

1. 在动作采样时记录每个已采样token的归一化logp和抽样位置完整logits。
2. 同一行为version的无梯度teacher-forced full replay重算；报告平均/p99/最大logp差、抽样位置全词表KL。
3. 再开gradient checkpoint与训练模式（dropout0）重算相同结果，并检查语言LoRA梯度非零、视觉及base梯度为空。
4. 超阈值先检查FP32cache、position IDs、温度、EOS、template、NF4版本和kernel；不能通过改stored logp掩盖。

根计划与各后缀分支的语言cache不能共享可变对象；每个视图新prefill。对同一个token序列，cache只是实现上的加速，未通过一致性门不能启动RL。门槛应以开发机实际浮点噪声制定并记录；例如mean abs logp≤0.01nat、p99≤0.05nat、抽样位置KL≤1e−3作为首轮实现检查值，若不满足，应修路径而不是直接放宽。以上均尚未GPU执行。

6.6.4 补充：RoPE偏移属于模型实例，不属于Cache

固定 Qwen3_5Model.__init__ 在1246设置 self.rope_deltas。PEFT的get_base_model1099–1103对LoRA返回被包装的HF模型。因此实际清理路径为 peft_model.get_base_model().model.rope_deltas = None。

必要性要准确限定：compute_3d_position_ids 的纯文本prefill分支（input_ids非空、past_len=0）返回None但不清理旧delta；自定义token循环若随后cached decode，可能在1520–1530加入上个图像请求的delta。**正常HF.generate在自己的位置准备函数1903–1918已经为纯文本新请求置零，不能误称其默认路径必然错误。**

统一worker约定：每个sample入口、每个reference full replay入口和每个policy full replay入口清理一次rope_deltas；每次动作新cache，同实例整次generate/完整backward串行。清理发生在一次请求的开始，**不在同一动作的每个decode token之前清理**。默认sample让HF.generate从本请求IDs/grid/mm_token_type_ids重新建立位置与delta；full replay从已保存输入重算完整position_ids，reference/current共用同一位置tensor。如果自定义token循环传显式position_ids，则必须在prefill从同请求get_rope_index取得delta并据此计算后续位置，不借实例旧值。增加“有图→无图→有图”以及branch切换的cache/reset对照即可。

6.7 9B DiT的可训练投影

DiT hidden为4096，8个双流block、24个单流block。双流训练attn.{to_q,to_k,to_v,to_out.0,add_q_proj,add_k_proj,add_v_proj,to_add_out}；单流训练attn.{to_qkv_mlp_proj,to_out}。单流融合输入为4096→36864，输出为16384→4096，LoRA因此同时涉及融合MLP通路。rank16、alpha16、dropout0：

$$N_\phi = 8 \cdot 8 \cdot 16(4096 + 4096) + 24 \cdot 16[(4096 + 36864) + (16384 + 4096)] = 31{,}981{,}568.$$

共112个模块、224个A/B张量；固定基座9,078,581,248参数。policy/reference都用FP32 LoRA，DiT forward BF16；SFT初始化A随机、B=0，RL从训练后的SFT A/B继续，不能沿用“RL第一步A必然零梯度”的说法。冻结VAE/BN、Qwen3-8B编码器、DiT原始参数和reference。适配器值按SFT快照独立复制，梯度边界与27B相同；两种框架的API不能混用。S2 S5 S24

DiT采用原生Diffusers PeftAdapterMixin，而非外包一层PeftModel。初始化调用transformer.add_adapter(config, adapter_name="policy")；SFT后用get_peft_model_state_dict(transformer, adapter_name="policy")取CPU克隆的LoRA值，新建同配置reference，再用set_peft_model_state_dict(..., adapter_name="reference")复制。对当前/参考逐张量验证值相等、storage独立，显式转FP32并冻结reference。DiT的transformer.set_adapter("reference") **不接受** inference_mode参数；切换之后显式将全部非policy参数冻结，reference前向用no_grad，切回policy后仅其A/B恢复requires_grad。参考切换期间也不应误将policy梯度清除。固定实现见Diffusers loaders/peft.py508–590。§6.4带inference_mode的调用仅适用于27B的PeftModel。

6.8 梯度如何穿过系统

SFT的CE更新θ，FM更新ϕ。共享task与bundle使两项监督对齐，但没有穿过离散PLAN反传。联合RL中，原始动作token的score更新θ，Gaussian转移score更新ϕ；已采样图像、JSON解析、hard mask、编译、冻结编码器和奖励均作为固定条件或环境运算。它们对后续决策的影响包含在完整轨迹分布中。

冻结语言/DiT基座不代表语言/DiT前向可以包在no_grad中：各层LoRA仍需通过固定投影向前层传递输入梯度。只有reference、纯rollout、视觉塔、条件编码器和判据使用无梯度路径。两模型优化同一个任务目标，数学细节见§11–14。

7. 数据来源、隔离、构建与筛选

7.1 数据与许可

数据	固定来源与用途	处理
MagicBrush	train/dev/test 多轮编辑；HF 6c254560879d f7851233ea0fd2ae2a62764d0ef2	train 用于构建；官方 dev/test 保留。按 session 和底层原图隔离
OmniEdit-Filtered-1.2M	HF b6eec40a8a6994aa380497e33b1964742d7e 028b	流式筛选子集；不下载约 TB 级全集；指令不冒充完整 caption
自建诊断与修复轨迹	来自训练分区图像和独立任务定义	保存注入、恢复、候选实测和私有标签
GenEval / GenEval2	官方评测	不进入 SFT、RL、教师提示选择或奖励校准
IV-Edit	固定数据卡未发现明确数据许可声明	不作为默认必需依赖；获得明确使用依据后再登记为补充评测

MagicBrush 官方当前说明 test 已公开；其 train/dev/test 分别为 4,512/266/535 个 session，8,807/528/1,053 个 turn。旧材料“测试集需申请”的说法已过时。MagicBrush 标注为 CC-BY-4.0，OmniEdit 数据卡为 MIT；还需保留底层来源图像记录，数据卡许可不自动消除原图来源约束。S12 S13

此前逐字节比对的核验记录确认：Tencent datasets/geneval2/synthetic/test.jsonl 与官方 GenEval2 的 800 条文件完全相同，均为 423,220 bytes，SHA256 为 09233adbc9f877fba205f1a20efa4a8640e7e62a91dfd55893562bed8a928e43。整个文件及其改写、教师衍生轨迹都禁止进入训练池。S14

7.2 划分先于展开

按以下连接关系建立数据 family：同一原图/目标图、同一编辑 session、同一实体参考来源、近重复图像、同一受控模板实例及其反事实。连通分量是最小划分单位。

预处理顺序：官方 test 隔离 → 精确内容 hash 去重 → pHash 汉明距离≤6 的候选检查 → DINOv2 cosine≥0.98 的候选人工/规则复核 → 固定 family → 按哈希划分 train/development/calibration/diagnostic-test。检测到相同底图跨官方 split 时从自建训练池移除相应 family；不修改官方测试集。

开发、校准与 500 个专项测试任务分别保留至少 200、600、500 个独立 family；数量不足时扩大候选数据，不从同一原图切出不同 crop 凑独立样本。RL 任务池默认 2,000 个训练任务，允许与 SFT 同属训练分区，但记录重合度并额外报告未见任务组合的结果。

7.3 DiT SFT 的 8,000 个初始样本

来源	无区域	1 区域	2 区域	合计
MagicBrush	2,000	1,200	800	4,000
OmniEdit	1,400	600	400	2,400
训练图像的完整 caption T2I	600	200	800	1,600
合计	4,000	2,000	2,000	8,000

这是来源与条件覆盖配额。两区域样本可以是“一处编辑＋一处保护/参考绑定”，另存 two_changed_entities 标签，不能把它们全部宣传为两对象同时编辑能力。

OmniEdit 起始过滤 sc_score_1⩾8、sc_score_2⩾8、pq_score⩾8，然后独立检查目标完成、内容一致、保护区域和图像配准。它没有普遍可信的原生区域 mask；RGB 差分只能提出候选，不能直接作为编辑真值。可靠区域来自已标注 mask、检测＋分割后复核、明确 bbox 或受控图像构造。无可靠区域的样本只进全局条件桶。

T2I 样本必须有完整图像描述，经冻结教师和人工抽查验证实体、数量、关系及背景；不能把“把帽子改红”当完整 caption。target的区域标注用于监督权重与兼容性筛选；真正输入DiT的区域来自下述公开PLAN或用户原本给出的控制。target像素和私有mask ID不进入PLAN/ConditionBundle。

appearance 样本占总量 10%，在各桶内部安排。优先从 source 的目标实体裁剪；跨图同身份任务必须有身份依据。默认不使用隐藏target crop重建条件（占比0%），完整target也不作为reference。新增外观参考任务必须在公共任务定义中显式提供对应crop并让Actor实际读到，不能从隐藏target临时补入。跨视角身份能力独立评测。

7.3.1 两侧SFT共享同一份计划与条件

对每个候选配对样本构造公开根视图：请求、原始source及确实允许的用户控制；冻结27B教师从此视图提出PLAN，编译器产生$c_i = \text{Compile}(G_i)$。私有target与标注仅在提案之后进入筛选器。只有语义兼容、公开引用合法、几何可靠的(x_i, G_i, c_i, I_i^*)进入联结数据。

所有8,000个DiT样本都保存task_id / root_view_hash / plan_token_ids / graph_revision / compiled_condition_hash / target_id；DiT消费c_i。从每个来源/区域格取一半，共4,000条PLAN供Actor SFT：

来源	全局PLAN	单区域PLAN	双区域PLAN	合计
MagicBrush	1,000	600	400	2,000
OmniEdit	700	300	200	1,200
完整caption T2I	300	100	400	800
合计	2,000	1,000	1,000	4,000

筛选至少检查：PLAN引用与类型全部合法；文本要求与配对target一致；对有可靠实体框且计划使用区域的样本，PLAN目标区域与已标注实体框IoU⩾.5；涉及source时独立检查source区域；对象身份/编辑指令保持一致。没有可靠区域依据则只进全局桶。不能把target框反写进教师的PLAN后仍称它是公开输入生成的计划。允许构造“用户明确给布局”的训练任务，但布局须出现在该任务公开根视图，独立打标并限制此类占25%；正式评测只能使用用户实际给出的控制。

教师最多对每个原始候选提案两次，第二次只纠正格式或公开合约问题，不把target检查结果作为提示来反复试答案。最多审12,000个原始候选，初始PLAN教师调用上限24,000；额外96条协议PLAN至多192次提案，1,024条规则恢复示范另计。目标配额未满足时报告实际数量；Actor对应格取实际有效样本的$\lfloor n/2 \rfloor$，不复制来伪造4,000个独立任务。原图核验、教师调用和render分别记账。

两侧初始监督因此具有相同条件语义：Actor学着提出c_i的公开来源，DiT学着执行c_i。私有target仍只承担监督和筛选作用，不增加推理时不存在的信息。

7.4 同状态的修复、回退与结束SFT

以“唯一状态包”组织数据，不再承诺16,000个相互独立的修复案例。一个包保存实际动作前状态及其经过执行验证的多个后继：

```
StateBundle:
 family_id, state_id, renderer_version, sampler_id, compiler_version
 public_before_view, public_dag_revision, source_image_id
 candidate_actions[], private_outcomes[], public_after_views[]
 verified_action_records[], intervention_node_set?, repair_node_set?
ActionRecord:
 state_id, phase, raw_input_ids, processor_artifacts
 target_ids, target_mask, public_reference_ids, verifier_provenance
```

数据先分 family，再展开状态和动作。离线教师复用 A0/A1 冻结 Qwen3.8-27B快照，输入严格等于该动作的serialized_actor_view(state_id)；规则 patch 提供候选，教师补文字与组合规划。先执行 schema、引用、frame、容量、条件 hash 校验，再执行至多两个真实不同的候选。自然失败没有唯一根因时，只监督有效修订及证据，不强造唯一错误节点。

一个失败状态可以提供 before→DRAFT_REPAIR、候选返回后 →APPLY、真实成功后的 →FINISH；发生回归的结果可提供 →SELECT历史图及其revision，恢复后 →FINISH或新的合法修订。每个目标有自己的真实动作前视图，不能把成功后的图放进修复前输入。历史错误动作 CE mask=0，当前核验目标 mask=1。有效修复不等于立即接受：如果修好了杯子却破坏了原有文字，数据应教回退或继续修复。

对固定状态 $s = (I_{\text{before}}, G_{\text{revision}}, h)$ 和候选 c：

$$I_c^{(r)} = \text{Render}_{\phi_{\text{SFT}}}(c, s; \epsilon^{(r)}), \qquad \Delta_c^{(r)} = Q_{\text{dense}}(I_c^{(r)}) - Q_{\text{dense}}(I_{\text{before}}).$$

所有复核 seed 的改善都减**同一个原始 before 图**。第二 seed 只改变候选生成噪声；重生成另一张 before 图就产生了新状态，必须另记 state ID，不能混入同一动作标签。

首轮每候选一个 seed。正修复要求 $\overline{\Delta}_c \geq 0.1$，且所有原先已知通过的必需要求，在每个用于验证的输出中仍已知通过；参与固定Q_{dense}的全部J项要求在before及每个用于验证的after中均须known，不用known交集重算分母。$\Delta \in [0.05, 0.15]$、判据冲突或回归不明确时优先进入第二 seed 配额；配额耗尽仍不确定的动作不贴正标签。存在必要阶段性退化时，只在完整后续轨迹得到验证后标为多步正样本。

第二 seed 复核固定 before，对两个候选各再执行一次，并预留一次显式 retry 对照。retry 复用选中图历史 producer 的完整条件、source/reference、版本，只换seed；它是同一状态下另一合法动作，**不替换 before，也不作为 RL baseline**。一条retry与两条repair的微小均值差不足以证明期望收益优势，只作为选样和诊断证据。配对噪声仅用于此类离线比较；在线兄弟 RLOO 仍独立。

受控注入分开保存两种证据。先在相同原始输入、版本与外生噪声下，只改变注入节点，验证正常图目标分≥0.8、坏图≤0.6；再从坏图的真实公开状态执行合法 DRAFT/APPLY，验证恢复图≥0.8。第二段默认以坏图为source，证明线上可恢复，并非“只撤回一个变量”的严格反事实。intervention_node_set 与实际 repair_node_set 可以不同。禁止用正确 target 当 reference、日志外换 source 或直接拷贝正常图充当恢复。两个注入seed得到两个不同坏状态，分别保存快照。

FINISH 优先来自完整成功、预算耗尽或真实回退后的状态。“继续收益非正”只指已测试候选和当前预算，不声称证明整个动作空间的最优停止。gold 仅用于事后过滤，目标里不能引用隐藏 eval ID、未来图像或私有答案。

7.4.1 有限数据预算与阶段依赖

先构建与配对样本对齐的4,000条PLAN示范，加96条复杂协议PLAN、1,024条可程序验证的合约错误/恢复示范；全部使用1024输出token上限。它们不需要新的DiT render，可与DiT配对图像SFT并行。**视觉修复数据必须等 DiT SFT 和 §12.4采样器选择完成。**默认不使用 ODE28 给 SDE50的修复动作直接贴正标签；若另用它预筛，正标签仍须在最终采样器上复核，额外调用入账。

构建项目	预算定义	render 上限
自然状态采集	1,024个起始任务尝试，每个1次初始生成	1,024
候选执行	每个上述状态最多2候选、各1seed	2,048
边界复核	最多256状态：两个候选第二seed＋一次retry	768
受控注入	256个正常/坏图/可执行恢复三联组	768

构建项目	预算定义	render 上限
注入复核	最多64个注入实例增加一组新seed三联	192
主构建小计	包括失败、未知和无有效标签的尝试	**4,800**
两轮自身状态纠错	2×256任务，每任务最多3次render	**1,536**
总计	不包括采样器门、RL pilot、正式评测	**6,336**

128个自然尝试、32个注入、32个自然复核、8个注入复核组成600-render数据 pilot，计入上述配额。1,024是尝试数，不是保证1,024个失败状态；成功初图也能生成停止监督。没有标签时不能无限补采到“16,000条”，也不降低通过阈值。先报告实际 unique family/state/action 数，再报告训练展示次数和过采样比例。需要扩大时增加明确的下一批预算。

自身状态纠错用当前控制器和固定 DiT SFT 版本收集真实轨迹；每轮256任务的3次render包含候选验证，不能在表外再追加候选枚举。每轮只对已经实际执行、核验成立的纠正动作进行100个 Controller SFT updates；默认不更新 DiT。若必须修改 DiT SFT，先建立新 renderer/sampler 版本，再重采受影响修复记录，不能沿用旧 outcome 宣称新模型有效。

加载器先抽 family，再抽 StateBundle，再按§8的阶段配额抽动作；同一个全局batch最多两个记录来自同一包。SFT构建时用真实 tokenizer 校验1024输出token容量；超长正确示范须拆为合法多动作，或登记扩大协议，禁止截断后监督。输入只能引用当时已披露工件，不能用 target mask 的私有artifact ID假装Agent早已知道其位置。

7.5 数据可靠性验收

每个数据桶抽 100 条；不足 100 则全查。记录任务完成、mask、身份、配准、原文覆盖五项正确率。任一关键标签错误率>5%，暂停该桶生成，修规则并重新抽样；不靠降低阈值补数量。训练前执行 family 交叉、已知 benchmark prompt、图像 hash、目标泄漏和未来信息检查。

某配额不足时先扩展同一训练分区候选和人工标注；仍不足则发布新的数据配置、按实际数报告，并保持无区域/单区域/双区域的采样比例。不能复制同一图冒充新增独立样本，也不能引入官方测试补足。首轮用每桶200个候选估计通过率，再按有效数/通过率估计后续成本。DiT原始配对筛选首批最多审查12,000对，目标得到§7.3的8,000对；不足则报告实得数量与缺口，不无限补齐。修复数据遵守§7.4的独立尝试上限。原始图像对核验、教师提案、公开检查与私有评分分别记账。

8. 两侧 SFT 的精确定义

8.1 按决策阶段、再按动作归一的 SFT

本设计避免长 PLAN/PATCH 占据绝大多数 token，使短的 SELECT/FINISH 几乎没有训练份额。它改变的是 SFT 示范权重，不改变 RL 的轨迹 score 定义。

令 $g \in \{1,2,3,4\}$ 为动作阶段，阶段权重 $q = (0.25, 0.35, 0.25, 0.15)$。完整修复 SFT 的全局 batch=20：

阶段	动作	每batch条数 n_g	权重
规划	PLAN、初始控制	5	0.25
修复执行	DRAFT_REPAIR、APPLY，含合法 retry	7	0.35
交付与回退	SELECT、FINISH	5	0.25
获取证据/恢复协议	INSPECT、READ_NODES、非法后合法恢复	3	0.15

每个记录预先唯一指定 phase；非法后恢复PLAN归第4类，不同时计入第1类。令 $m_{i\ell} \in \{0,1\}$ 为第 i 个动作的有效监督mask，$d_i = \sum_\ell m_{i\ell} > 0$：

$$\ell_i^{\mathrm{CE}} = -\frac{1}{d_i} \sum_\ell m_{i\ell} \log \pi_\theta(y_{i\ell} \mid h_{i\ell}), \qquad \mathcal{L}_\theta^{\mathrm{SFT}} = \sum_{g=1}^{4} \frac{q_g}{n_g} \sum_{i:g_i=g} \ell_i^{\mathrm{CE}}.$$

system/user/tool/固定空think前缀/图像占位、历史错误、padding 为0；当前经过核验的目标动作与正确 im_end EOS为1。mask按真实长度与角色位置生成，不按PAD token ID屏蔽，因为27B的PAD与一种EOS相

同。未确认根因的文字删除或对应span置0，有效patch仍监督。token边界用原始IDs与构造时span，不用字符串搜索。全零目标拒收，分布式padding不计分母。

各rank每动作贡献 $q_g \ell_i / n_g$，n_g 是全局配额；SUM all-reduce 后不再除 world size。不足某phase则继续累积到完整配额，不把剩余phase权重临时重归一。采样重复是明确的过采样，不能再乘一层同样的阶段权重。协议预热阶段尚无四类数据时，采用可用协议动作的单动作CE平均，记为独立阶段；不伪装完整phase-balanced训练。

SFT允许示范EOS；RL人工补EOS的策略mask必须为0。主RL阶段不重复加入CE/FM回放，SFT能力由固定reference KL约束保持。**RL不采用每动作实际长度平均**，仍用 § 13固定预算分母，否则会改变目标。

同状态修复包让模型学到何时修、何时保留和回退；阶段均衡让这些动作都有明确监督份额。对 DiT， § 8.2 同时适配区域文本、source/target mask和参考条件，因此SFT的作用也体现在实际控制执行，而不仅是JSON格式。两项均需用去掉对应SFT的对照验证。

8.2 DiT flow matching

令样本 b 的 packed 目标为 $x_{0,b} \in \mathbb{R}^{1024\times128}$：

$$
\begin{aligned}
u_b &\sim \mathcal{N}(0,1), \quad \sigma_b = \mathrm{clip}(\mathrm{sigmoid}\, u_b, 10^{-4}, 1-10^{-4}),\\
\epsilon_b &\sim \mathcal{N}(0, I_D), \quad D = 1024 \cdot 128,\\
x_{\sigma,b} &= (1-\sigma_b)x_{0,b} + \sigma_b \epsilon_b,\\
v_b^\star &= \epsilon_b - x_{0,b}.
\end{aligned}
$$

$\sigma = 1$ 是噪声，$\sigma = 0$ 是数据，速度方向为对 σ 求导。空间监督在 target 网格，p 为 patch，c 为 128 个通道：

$$
\begin{aligned}
w_{bp} &= m_{bp}^{\text{valid}}(1 + 3m_{bp}^{\text{edit}}),\\
e_b &= \frac{\sum_{p,c} w_{bp}(v_{\phi,bpc} - v_{bpc}^\star)^2}{128 \sum_p w_{bp}},\\
\mathcal{L}_\phi^{\text{FM}} &= \frac{\sum_b m_b^{\text{sample}} e_b}{\sum_b m_b^{\text{sample}}}.
\end{aligned}
$$

valid 是实际有效像素的面积池化，edit 是可信编辑区域并集的面积池化，sample 处理样本级 padding。参考与 source 输出直接切除，不计随机维数或 target loss。没有可靠编辑 mask 时 edit=0；真实样本 $\sum_p w_{bp} = 0$ 时拒收，不能用 epsilon 掩盖坏数据。仅对sample=1的样本计算e_b；dummy贡献结构零，不先算0/0再乘0。$\sum_b m_b^{\text{sample}}$是汇总后的全局有效样本数，各rank使用这一分母，SUM梯度后不再除world size；全局有效数为0则跳过更新。

σ, ϵ 和文本 dropout 由 H(sample_id,epoch,step,stream_tag) 的独立流派生。SFT 用单支预测，整组文本 dropout 概率 0.1。Tencent 的通用 SFT 训练路径未使用其评价路径的 sample loss mask，因此在本项目 train/fm_loss.py 返回未 detach 的逐样本误差再归约；不能拿已经 detach 的 aux loss 做 backward。S6

8.3 一条可以直接构建的数据实例

原请求是“木桌上的红杯位于蓝书左侧；把书上的文字改成HELLO，保留其他内容”。公开输入只有原图和这句话。Agent创建杯/书实体及独立source/target区域；CheckSpec由冻结公开分解器给出颜色、位置、文字与保留检查。二者的ID不同于隐藏评分ID。

第一次结果把文字改对，却把杯子变蓝。公开图像与颜色检查使错误候选收缩到杯子控制/绑定和本次render；不能直接断言唯一根因。教师在这个真实before视图提出“只修杯子”和“扩展到邻接书区域”两个候选，编译后条件hash必须不同。一个候选若得到红杯、HELLO仍正确，就可生成before→DRAFT/APPLY、after→FINISH监督；另一候选若红杯正确但文字退化，则该after只提供SELECT旧图/进一步修复的上下文，不能标成成功接受。

两个结果都从同一个before状态产生，保留各自实际公开观察。隐藏评分只决定哪些目标动作通过离线筛选，绝不作为输入告诉Agent“第几个候选最好”。若要第二seed，仍保留这张蓝杯before图，只重采候选执行。这

个数据组织把DAG修订、视觉检查、保护原有正确项和停止决策落在同一套可运行记录里；它无需给自然失败编造唯一因果标签。

9. 评价器、工具接口与奖励可靠性

9.1 工具输出契约

公开观察返回 image_hash,check_id,value,known,verdict,evidence_ids,tool_version,frame,entity_matches；私有评分使用独立 eval_id 和独立存储。Observer只能访问CheckSpec，RewardService只能在回合结束后返回给learner。相同judge权重可复用，但请求队列、DTO、缓存命名空间与日志权限分开。unknown是内容无法可靠判定，infra_error是服务未完成，二者不能合并。

GroundingDINO 的标准输出为归一化 cxcywh，转换一次为 canvas xyxy。初始 box/text 阈值 0.35/0.25，新增类内 NMS IoU=0.5；检测 raw score 不当作正确概率。SAM2 predictor 的图像特征状态必须绑定 image hash，每个并发请求独立实例或串行锁。DINOv2 ViT-B/14 仅作外观和保护区辅助，不替代身份真值。S15

工具变体固定为 GroundingDINO Swin-T OGC（GroundingDINO_SwinT_OGC.py、groundingdino_swint_ogc.pth）、SAM2.1 Hiera-small（configs/sam2.1/sam2.1_hiera_s.yaml、sam2.1_hiera_small.pt）、DINOv2 dinov2_vitb14（无register tokens）。GroundingDINO的BERT依赖固定 google-bert/bert-base-uncased@86b5e0934494bd15c9632b12f734a8a67f723594，配置指向固定本地snapshot。各权重在实施下载时计算SHA256，不能用文件名或HTTP长度代替校验。

视觉工具使用独立A6000环境：Python3.10、torch2.6.0+cu124、torchvision0.21.0、Transformers4.48.2。GroundingDINO扩展以CUDA12.4 toolkit、TORCH_CUDA_ARCH_LIST=8.6编译；在项目兼容补丁中将CUDA源码的 value.type() 分派改为 value.scalar_type()，并将 .type().is_cuda()、.data<T>() 改为 .is_cuda()、.data_ptr<T>()。该固定核只分派float/double，Python没有BF16处理分支，因此检测模型/输入默认FP32、禁autocast。启动验证 _C 可加载及CPU/GPU结果，不把CUDA扩展失败当成自动回退。S15

SAM安装设 SAM2_BUILD_CUDA=0；build_sam2(...,apply_postprocessing=True)保留原生稳定性后备，predictor设 mask_threshold=0,max_hole_area=0,max_sprinkle_area=0，不调用可选连通分量CUDA后处理。输入RGB uint8，框提示由归一化xyxy乘canvas尺寸变为像素坐标，multimask_output=False。SAM可用BF16 forward，持久mask转float32。DINO在import前设 XFORMERS_DISABLED=1，使用普通密集batch、FP32和原生SDPA。

检测沿用官方确定性resize：短边800、长边≤1333，ImageNet mean/std。内部DINO统一224×224：whole canvas等比缩放并灰色padding；实体crop先按bbox裁剪再等比缩放padding；bicubic、ImageNet mean/std固定。CLS外观特征为768维并L2归一化；保护比较取16×16 patch网格，对保护mask执行同一变换和14×14面积池化。非有限或零范数特征为工具错误，不伪造相似度。SAM维持自己的processor，不把DINO/检测的归一化张量直接传入。

OCR 默认只处理数据集中明确标注的短英文/数字，调用 Tesseract 5.5.0、tessdata_fast@4.1.0/eng.traineddata、OEM=1、PSM=11，按 Unicode NFC、大小写遵从任务的 exact string 比对；不在首轮加入未校准中文 OCR 任务。OCR 结果同时给 crop 和 confidence；初始 confidence<80 或文本不可见为 unknown，阈值按同一独立校准流程冻结。工具二进制和 traineddata hash 进入 manifest。S19

9.2 冻结32B判据与有界二次复核

Qwen3-VL-32B-Instruct采用固定NF4底座、BF16算术、no-grad、microbatch1。只量化语言层448个大Linear（31,205,621,760参数），跳过model.visual、lm_head；embedding自然不转换。模型总参数按官方index为33,357,390,064，非量化2,151,768,304；静态约19.00GiB，模型/处理器和量化状态固定。它与27B Actor不同：64层全attention、hidden5120、64Q/8KV头、head_dim128、vocab151936，而且存在DeepStack[8,16,24]。用其自己的AutoProcessor和官方forward，不借用27B的无DeepStack路径。S23

输入为候选图、必要source/identity reference（最多两图）和一项要求；每图上限262144像素，总输入上限8192 token，超限在任务准入时分流，不静默截断。patch16、temporal2、merge2：512^2图对应grid[1,32,32]、pixel_values[1024,1536]、256视觉token。所有检查都读图像和要求，不读Agent自报成功。

判据不生成长解释再解析；用固定答案序列Yes+im_end、No+im_end做条件似然比较。真实tokenizer可能将答案分为多个token，保存其实际IDs，不假定单token：

$$\ell_c = \sum_{k=1}^{|v_c|} \log p_\omega(v_{c,k} \mid h, v_{c,<k}), \qquad p_Y = \mathrm{sigmoid}(\ell_Y - \ell_N), \quad c \in \{Y, N\}.$$

答案不按长度平均，EOS为该judge自己的im_end（151645），与Actor的248046不同。completion位置才计算logits；相同问题的Yes/No可批处理，逻辑query与物理forward次数分别记录。

两个固定英文模板的任务部分如下，实体名、要求和引用均由对应CheckSpec/EvaluationSpec字段填入：

Template A:
Inspect the attached image(s). The first image is the candidate.
Any additional image has the role stated below.
Request context: {original_request}
Image roles: {roles}
Check exactly this property: {atomic_property}
Does the candidate visibly satisfy the entire property?
Answer only Yes or No. Judge the image, not an assistant's claim.

Template B:
Compare the candidate with the stated requirement and any named reference.
Request context: {original_request}
Image roles: {roles}
Required property: {atomic_property}
Is this property clearly supported by what is visible in the candidate?
Answer only Yes or No. Do not infer a requested object is present merely
because it is mentioned in the requirement.

先执行A得到p_1。仅在$p_1 \in [.2, .8]$、结构化证据冲突，或预登记困难类型（精确计数、文字、跨图身份）时执行B。第二路由与阈值在校准前写入配置，不能根据训练收益临时改变。只执行A时$q_j = p_1$；执行B时$q_j = \min(p_1, p_2)$。$|p_1 - p_2| > .25$、未解决的工具冲突或语义证据不足为unknown；非有限数值/超时/设备错误属于infra_error，不能伪装内容未知。最终通过阈值按类型校准；.8仅为初始候选值。

600个独立校准任务按family分为400选阈值、200确认，双人标注并裁决分歧。每类型至少100个原子标注，报告precision/recall、ECE、Brier与unknown率，并按任务聚类给区间。在$\{.50, .55, \ldots, .95\}$中选通过precision的Wilson95%下界≥.85的最低阈值；确认集不再选阈值。类型未达门时补标注或使用明确的结构化路线，不能仍将其不可靠的Yes作为成功。校准的是**实际NF4模型加完整路由**，不是先校准BF16然后直接换量化模型。

公开反馈与私有奖励共享同一组冻结权重也必须分开输入标准、ID、队列、DTO、缓存命名空间和响应接收者。CheckSpec由32B冻结分解器从公开请求产生；其覆盖率、误报与幻觉约束率单独评估。两个措辞不是两份独立真值；最终效果还由官方判据和人评核对。调用量为每原子1–2个query，预算见 § 17。

9.3 几何、计数和参考

可靠检测并完成身份匹配后：计数软分为 $\exp(-|n-k|)$，精确通过要求 $n = k$；左右关系用中心坐标，容差为画布宽度 0.02；包含关系用交集占被包含框面积，通过阈值 0.9。布局 IoU 仅在**用户或数据标注明确给出目标框**时使用，不能把 Agent 自选 bbox 当奖励真值。

VLM 与几何矛盾、漏检或身份不明确时标记 unknown，不能以“没检测到”证明对象不存在。外观要求同时检查实体 crop 的 DINO 相似度和语义参考一致性；相似度阈值按该要求类型的校准集选择，不把固定 cosine 当身份保证。保护区域来自原始任务，不允许 Agent 缩小。

10. 回报定义及边界情况

本节所有要求、分数、CS与保护项均为私有终评量，不作为回合内反馈。仅实际交付图和原始source参与默认回报；中间图的隐藏评分需要离线追加且单列成本。

设固定要求数为 $J \geq 1$，有效判定为 $o_j \in \{0, 1\}$，通过阈值为 τ_j，软分为 $q_j \in [0, 1]$：

$$\tilde{q}_j = o_j q_j, \quad p_j = o_j \mathbf{1}[q_j \geq \tau_j], \quad \mathrm{CS} = \prod_{j=1}^{J} p_j.$$

对具有精确离散通过条件的类型，p_j 使用该条件与 known 的合取；软分仍用于密集反馈。

$$Q_{\text{dense}} = 0.7\frac{1}{J}\sum_j \tilde{q}_j + 0.3\min_j \tilde{q}_j.$$

采用均值＋最小值是为了在某一项仍为 0 时保留其他要求改善的信号；完整成功另由 CS 表达。没有沿用“一项为零便使全部密集项为零”的几何均值。

编辑任务以原始 source canvas 为 I_0，不是首次渲染。P_0 为原始图已经通过、且本任务要求保留的要求集：

$$\text{reg} = \frac{1}{|P_0|}\sum_{j\in P_0}[p_j(I_0) - p_j(I_T)]_+.$$

P_0 为空时 reg=0。保护 mask 为 $M = m^{\text{protect}} m^{\text{valid}}$：

$$d_{\text{pix}} = \frac{\sum_{x,y,c} M_{xy}|I_{T,xyc} - I_{0,xyc}|}{3\sum_{x,y} M_{xy}},$$

$$\text{keep} = \tfrac{1}{2}e^{-d_{\text{pix}}/0.05} + \tfrac{1}{2}\,\text{mean}_{p\in\Omega}\,\frac{1+\cos(f_p(I_T), f_p(I_0))}{2}.$$

Ω 是保护覆盖率≥0.5 的 DINO patch；若有效保护像素存在但 Ω 为空，keep 只用像素项，不乘 1/2。没有保护区时 keep=1。特征在固定 resize/padding 后计算，mask 同步变换；不能用 latent 的 32×32 网格直接索引 DINO 的网格。

逻辑成本为

$$\widetilde{C} = \frac{n_{\text{render}} + 0.1n_{\text{inspect}} + 0.01n_{\text{action}}}{3 + 0.1\cdot 2 + 0.01\cdot 10} \in [0,1].$$

缓存命中仍按该逻辑请求计费；真实缓存节省另作系统指标，避免兄弟分支通过共享缓存影响彼此 reward。FINISH不额外奖励或惩罚成功自报；正常交付回报为：

$$R = \text{CS} + 0.3Q_{\text{dense}} - 0.15\text{reg} - 0.05(1-\text{keep}) - 0.1\widetilde{C} - 0.02n_{\text{invalid}}.$$

正常回合最多有一次非法动作，负项总上界为 $P_{\max} = 0.32$。因此任意完整成功回合 $R \geq 0.68$，任意未完整成功回合 $R \leq 0.3$，成功严格占优。改变权重时，启动检查必须重新验证 $1 - P_{\max} > w_{\text{dense}}$（当前$w_{\text{dense}} = 0.3$）。两次非法、显式FINISH(null)或无可交付图统一回报 −1，不另叠加成本，故总体 $R \in [-1, 1.3]$。

unknown 使对应 $\tilde{q}_j, p_j$ 变为 0，不移除分母；在其他量固定时不能提高任务分。基础设施导致未拿到图或评分时，整个组仍未完成，不按 unknown/−1 入训练。评价器内容盲点仍可能被优化利用，必须用独立审计和人评监测，而不能仅凭上述有界性宣称奖励不可被利用。

原ACCEPT与STOP对同一图像只有失败惩罚差别，STOP弱支配ACCEPT；v3用单一FINISH消除这个无助于决策的自由度。回报鼓励完整满足、保护已正确内容和节制执行成本，结束动作本身没有额外语言标签奖励。主路径不添加在episode级RLOO中会抵消的势函数项。

11. 行为记录与联合概率

11.1 Token、图像与版本记录

每动作保存 raw_prompt_ids、raw_completion_ids、behavior_log_probs、response_mask、finish_reason、view_hash，以及 processor 实际返回的 pixel_values、image_grid_thw、attention_mask、mm_token_type_ids 与模型/processor revision。RL 的 mask 覆盖模型真实采样的全部动作 token、理由、非法内容、采样 EOS；环境 token、输入前缀图像占位、padding、人工补EOS为0；completion实际采到的特殊视觉token仍计score。达到长度上限的真实 token 仍为 1。

27B worker保存本次processor的真实输出、模板开关、量化底座hash及位置生成规则。有图必须提供mm_token_type_ids；拼接动作后追加文本类型0。每动作采样用新的FP32-recurrent hybrid cache；replay设use_cache=False,past_key_values=None，从完整输入计算位置和有梯度的chunk GDN。不得detach前缀后只训练后缀。参考和当前使用相同输入/位置；具体cache修复见§6。27B没有DeepStack，32Bjudge的DeepStack仍由其自身forward处理。

固定模板设置enable_thinking=False,preserve_thinking=False,tools=None。空think块是prefix，mask0；原始采样内容（包括错误JSON及EOS）都是策略事件。采样显式设temperature1、top_p1、top_k0、min_p0、repetition_penalty1，禁用未纳入score的logits过滤。SFT用im_end；RL两种真实EOS都计分，PAD由位置和长度掩码排除。

processor的多图 pixel_values 按实际grid长度切成逐图不可变tensor工件，视图记录有序工件引用和拼接offset，避免每个动作重复保存同一源图。replay重组这些已经保存的tensor，核对拼接hash；不得从变化后的DAG重取图像。全量保留当前阶段，阶段归档与latent链使用同一审计保留策略。

每 render 保存：

```
render_id, task/root/branch IDs, behavior_version, bundle_hash
z_fp32[T+1,1024,128], sigma_fp32[T+1], transition_std[T]
seed_init, seed_steps[T], stored_mean_logp[T]
probe_mean_fp32[selected_steps]?, final_image_id
compiler/encoder/judge/backend versions, status, logical_cost
```

每轮记录 task_id、root_id、branch_id，三者不混用。Agent 可见节点 ID 是分支局部稳定别名；全局唯一 ID 只用于内部来源追踪，避免调度顺序泄漏兄弟分支的信息。

11.1.1 视觉前缀装配与异常动作完整重放

全支持策略可能在completion采到image_token_id=248056等特殊token。原生multimodal forward的get_placeholder_mask按整段IDs统计图像占位，不读取mm_token_type_ids；有图prefix加上这种completion会导致特征计数不匹配。cached decode首轮之后不再传pixel_values，故该采样事件本身可以发生。不能因此丢掉轨迹、偷偷删token或改变策略支持集。S3

重放统一显式执行官方forward的冻结输入装配部分：

1. 行为视图生成时保存真实prefix_image_positions、prefix长度、图像顺序与merger feature offsets/hash；仅这些槽位是图像。prefix槽数与图像特征数必须相等，不能重放时搜索整个completion。
2. 用同一个冻结embedding为完整prefix＋completion构造[1,L,5120] BF16 inputs_embeds；只向已保存prefix槽位scatter冻结merger特征。completion内所有token保留其普通embedding与类型0。
3. 由保存IDs、grid、attention mask和扩展类型0调用hf.model.get_rope_index取得[3,1,L]位置；无图时三轴使用普通顺序位置。拼接普通text位置[1,1,L]成为[4,1,L]，reference/current共享。所有prefix位置和completion位置须与实际cached生成对齐。
4. hf=peft_model.get_base_model()；调用hf.model.language_model(inputs_embeds=..., position_ids=..., attention_mask=..., past_key_values=None, use_cache=False, return_dict=True)得到最后层hidden。语言LoRA与checkpoint仍在该模块内部，完整前缀梯度保留。
5. 按§14先reference no-grad再policy完整图，进行冻结head位置分块和一次decoder VJP；不重新物化全部层hidden。

固定源码的multimodal forward本身最终也是如此调用language_model，见S3的1564–1606行；TextModel在1173–1197行区分4轴中的text位置和3D位置。这里是同一官方运算的显式拆分，视觉/embedding可冻结缓存，语言activation不能作为有梯度replay的替代。

JSON解析用skip_special_tokens=False的解码；只按真实采样边界去掉一个实际终止EOS，不把completion内部其他特殊token静默删掉以修好JSON。验收增加“有图prefix＋completion含image/video/start/end特殊ID”的固定case：重放完成、全部原始score保留，协议可以判非法。普通0/1/4图路径与原生multimodal hidden/logp做等价对照。

11.2 概率事件与目标

任务记为 ξ，完整轨迹为 τ，动作是原始采样 token 序列 a_t，实际第 e 次生成的条件为 c_e。固定 compiler、工具和判据后：

$$
\begin{aligned}
p_{\theta,\phi}(\tau \mid \xi) = p_{\text{env}}(\tau \mid \xi) \prod_t \pi_\theta(a_t \mid s_t) \\
\cdot \prod_{e \in \tau} \prod_{k=0}^{T-1} q_\phi(z_{e,k+1} \mid z_{e,k}, c_e), \\
J(\theta, \phi) = \mathbb{E}_{\xi \sim \mathcal{D}, \tau \sim p_{\theta,\phi}}[R(\tau)].
\end{aligned}
$$

p_{env} 包含初始标准正态和确定性状态转换，不直接含可训练参数；工具若有随机性，使用固定、独立 RNG 并计入环境。动作概率为其所有采样 token 条件概率的乘积。

$$
\nabla_\theta J = \mathbb{E}\left[R \sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right],
$$

$$
\nabla_\phi J = \mathbb{E}\left[R \sum_{e,k} \nabla_\phi \log q_\phi(z_{e,k+1} \mid z_{e,k}, c_e) \right].
$$

给定动作后 c_e 不再直接依赖 θ；控制器对条件选择的影响已在动作概率中。包括被放弃的图像在内，所有实际 render 都计入 score，因为它们可能影响后续修复与停止。未执行的候选没有生成 score。合法零 render 编辑轨迹的 ϕ 求和为空，其回报仍进入分支基线。

默认采样 temperature=1、top-p=1、top-k=0，无 grammar 截断。日后使用约束解码必须保存每位置允许集合，并按实际集合重归一化概率；不能用原始 full softmax 概率替代行为概率。

12. Flow-SDE 的完整数学与实现

12.1 唯一 sigma 表

噪声段 token 数 $L = HW/256 = 1024$，步数 $T = 50$。按固定官方实现定义：

$$
\begin{aligned}
m_{200} &= 0.00016927L + 0.45666666, \\
m_{10} &= 0.0000873809524L + 1.89833333, \\
\mu_{\text{shift}} &= \begin{cases} m_{10} + \dfrac{T-10}{190}(m_{200} - m_{10}), & L \le 4300, \\ m_{200}, & L > 4300, \end{cases} \\
t_k &= 1 - k/T, \qquad k = 0, \ldots, T-1, \\
\sigma_k &= \frac{e^{\mu_{\text{shift}}}}{e^{\mu_{\text{shift}}} + 1/t_k - 1}, \qquad \sigma_T = 0.
\end{aligned}
$$

这是指数型 shift，μ_{shift} 不是 Gaussian 均值。只按 target 噪声 token 数算日程，不把文本/source/appearance 的长度加进 L。构造一次并保存完整 float32 数组与 hash；采样、当前重放和 reference 共用它，不分别重算。S4

12.2 转移核

将 $[1024, 128]$ 展平为 $D = 131072$ 维。每步：

$$
\begin{aligned}
\Delta_k &= \sigma_{k+1} - \sigma_k < 0, \\
\tilde{\sigma}_k &= \begin{cases} \sigma_1, & k = 0, \\ \sigma_k, & k > 0, \end{cases} \\
d_k &= \eta \sqrt{\frac{\sigma_k}{1 - \tilde{\sigma}_k}}, \qquad s_k = d_k \sqrt{-\Delta_k}, \quad \eta = 0.3, \\
a_k &= 1 + \frac{d_k^2 \Delta_k}{2\sigma_k}, \\
b_k &= \left(1 + \frac{d_k^2 (1 - \sigma_k)}{2\sigma_k}\right) \Delta_k, \\
\mu_{\phi,k} &= a_k z_k + b_k v_\phi^{\text{cfg}}(z_k, \sigma_k, c_e), \\
q_\phi(\cdot \mid z_k, c_e) &= \mathcal{N}(\mu_{\phi,k}, s_k^2 I_D), \\
z_0 &\sim \mathcal{N}(0, I_D), \qquad z_{k+1} = \mu_{\phi_{\text{old}},k} + s_k \epsilon_k, \quad \epsilon_k \sim \mathcal{N}(0, I_D).
\end{aligned}
$$

d_k 是扩散系数，s_k 才是实际单步标准差。所有主状态、均值、采样、logp 和 KL 使用 FP32；仅 DiT 输入和 forward 为 BF16。模型输出先转 FP32，再进行 CFG 混合。存储 $z_0, \dots, z_T$ 的 FP32 链，实际 BF16 输入由同一个 cast 派生。

普通算术得 $\mu_{\text{shift}} \approx 1.7019562073$、$\sigma_1 \approx 0.9962928450$、$\sigma_{49} \approx 0.1006643969$、$s_0 = 0.3$、$s_{49} \approx 0.0318446337$。最后一步仍有正方差；这不是质量结论。

12.3 密度与抽步

总对数密度和每维平均为：

$$
\begin{aligned}
\ell_{\phi,e,k} &= -\frac{1}{2} \sum_{d=1}^{D} \left[\frac{(\text{sg}(z_{e,k+1,d}) - \mu_{\phi,e,k,d})^2}{s_k^2} + 2 \log s_k + \log(2\pi) \right], \\
\bar{\ell}_{\phi,e,k} &= \ell_{\phi,e,k} / D.
\end{aligned}
$$

sg 表示停止梯度。replay 的当前/下一状态、条件、sigma、std 全部固定，只对当前 velocity 的 LoRA 求导。reference token 不属于随机动作。配置检查要求所有 $s_k > 10^{-8}$ 且有限，不允许运行中静默删掉某些步。

默认所有50步随机，保存51个状态；学习时用独立RNG按 § 13.4四个时间层各抽1步。stochastic_indices=range(T)与train_indices是两个字段。Tencent的sde_indices同时影响注噪与保存，必须传全体步骤，不能把4个重放步传给它。S6

选择全步 SDE 是为了使本方案“黑箱奖励＋逐步 score＋整链 detach”的梯度定义闭合。若使用同一可训练参数的确定性后缀，却既不求其路径导数也不改变策略定义，会漏掉该部分参数影响；窗口 SDE 可作为另一 surrogate，但不能不加说明地混入本目标。ODE 的 $\eta = 0$ 只用于独立推理对照，不给它伪造 Gaussian logp。

12.4 采样器质量门：50步默认，20/28步待验证

按同一源码和 $\eta = 0.3$ 的CPU复算：

T	shift μ	最后一个非零 σ	末步实际标准差
20	1.91634762	0.26345430	0.09209302
28	1.85917658	0.19206305	0.06410270
50	1.70195621	0.10066440	0.03184463

20步的末端注噪约是50步的2.89倍。公式闭合不等于有限步图像质量相同；也不能偷偷把末步改成ODE继续沿用当前Gaussian目标。S4 S9

DiT SFT完成后，固定64个开发任务/控制条件，涵盖0/1/2区域、生成/编辑及参考，每任务2个预定外生seed，

比较50步ODE、50/28/20步全SDE（CFG4、η=.3），共512 renders。控制条件和任务保持相同；不同步数本来就是不同转移链，只对齐初始seed和可定义的外生随机规则，不声称逐步噪声一一等价。

先检查50步SDE相对ODE的任务完成、保护和盲评质量。初始可接受门槛为成功率点差不低于−5个百分点、严重视觉缺陷增加不超过5个百分点，同时报告配对置信区间；若区间无法排除更大退化，扩大到独立开发任务复核，不把“没有显著差异”当等价。默认质量不合格时依次测试50步η=.15、80步η=.15，各128 renders；六种配置合计最多768次初筛。追加独立复核另列预算。

20/28步只有对已经合格的50步配置通过同一质量门、且实测端到端吞吐提高时才取代默认；不确定时保留50步。选择完成后锁定 sampler ID，修复SFT、Agent RL、联合RL、主测试和所有直接对照都使用它。50步ODE作为额外推理结果另报，不能只在主测试悄悄换采样器。若仍没有可用全SDE配置，先修采样数值/条件适配并重做该门，不以一个未验证的短链直接开始大规模数据采集。

本版的采样器门在9B上重新执行；不能沿用4B图像的通过结论。50步sigma数值保持一致，是因为512网格的L=1024不变，并非因为两模型的图像质量相同。门测试同时比较原生全局条件、区域条件和source/reference编辑，在已完成DiT SFT的模型上排除条件编译退化，再进入修复SFT/RL。

13. 分层采样、信用分配、损失与正则

13.1 采样和独立性

每轮 $P = 6, N = 2, M = 2$。任务索引 p，根计划索引 n，后缀索引 m。先独立采 N 个根动作，再对每个根动作 fork M 个后缀；首次 render 在 fork 后。两个根偶然相同仍保留，不去重补采。

启动断言 $P \geq 1, N \geq 2, M \geq 2, T \geq 4, 1 \leq K_s \leq T$，所有预算和token上限为正整数。N或M为1时拒绝该RLOO配置，不以零baseline静默替换。小批不足时延后收集完整组，不通过减小组大小完成更新。

每条后缀独立控制器、初始噪声和 SDE 流：

$$\begin{aligned}
\text{seed}_{\text{ctrl}} &= H(\text{run}, \text{round}, p, n, m, t, \text{ctrl}),\\
\text{seed}_{\text{init}} &= H(\text{run}, \text{round}, p, n, m, e, \text{init}),\\
\text{seed}_{\text{SDE}} &= H(\text{run}, \text{round}, p, n, m, e, k, \text{sde}).
\end{aligned}$$

根动作 RNG 不含 m；训练抽步另用 step_subset tag。hash 截为无符号 64 位 seed，原始元组也保存。工具不使用全局 RNG。兄弟分支的可见 ID、预算、候选、图像指针和奖励成本都独立；共享只读编码缓存不暴露缓存命中或其他分支排队延迟。

13.2 分层 RLOO

$$\begin{aligned}
\bar{R}_{pn} &= \frac{1}{M}\sum_{m} R_{pnm},\\
A^{0}_{pn} &= \bar{R}_{pn} - \frac{1}{N-1}\sum_{n' \neq n} \bar{R}_{pn'},\\
A^{+}_{pnm} &= R_{pnm} - \frac{1}{M-1}\sum_{m' \neq m} R_{pnm'}.
\end{aligned}$$

根基线独立于当前根动作；给定根动作后，兄弟后缀基线独立于当前后缀。因此 $\mathbb{E}[b\nabla \log p] = 0$。根采用 A^0，所有后缀动作与全部 render 采用 A^+。因为 $\sum_m A^+_{pnm} = 0$，把后缀优势用在共享根上会消掉根梯度；这是本估计器的限制，不意味着所有共享前缀方法都不能训练。

不除组标准差，不裁优势，不过滤失败或零分。由总体回报范围，优势位于 $[-2.3, 2.3]$；$M = 2$ 时就是两个回报之差。恒定回报组保留在分母中，PG 自然为零。

13.3 控制器 PG 与 KL

令 s^0_{pn} 为根动作全部策略 token 的 logp 之和，s^+_{pnm} 为该分支后续动作 logp 之和，固定 $C_\theta = 10 \times 1024 = 10240$：

$$\mathcal{L}_{\theta,\mathrm{PG}} = -\frac{1}{PNC_\theta}\sum_{p,n}\mathrm{sg}(A^0_{pn})s^0_{pn} - \frac{1}{PNMC_\theta}\sum_{p,n,m}\mathrm{sg}(A^+_{pnm})s^+_{pnm}.$$

根只计一次；不按实际输出长度平均。每位置完整词表 KL 为

$$K_\theta(h) = \sum_{v\in\mathcal{V}}\pi_\theta(v\mid h)\log\frac{\pi_\theta(v\mid h)}{\pi_{\mathrm{ref}}(v\mid h)}.$$

根与后缀各自的策略 token 集为 $\mathcal{T}^0, \mathcal{T}^+$，聚合必须明确为

$$\mathcal{K}_\theta = \frac{1}{PNC_\theta}\sum_{p,n}\sum_{\ell\in\mathcal{T}^0_{pn}}K_\theta(h_\ell) + \frac{1}{PNMC_\theta}\sum_{p,n,m}\sum_{\ell\in\mathcal{T}^+_{pnm}}K_\theta(h_\ell).$$

KL 不乘优势。用词表完整归一化，不能对词表小块分别 softmax。从完整decoder forward只取目标token前驱位置的最后层hidden，按 § 14.2每32个位置分块投影完整词表，再把hidden梯度一次送回decoder。不是先物化所有动作logits再切块；decoder采用非重入checkpoint。S3

13.4 覆盖四个时间层的渲染器 PG 与 KL

每个实际render的完整T步均为随机策略动作，只为反向计算抽取 $K_s = 4$ 步。将 $0, \dots, T-1$ 划为四个连续、不相交时间层 $\mathcal{S}_h$：令 $q = \lfloor T/K_s \rfloor, r = T \bmod K_s$，前r层长q+1，其余长q。T=50时为 [0,13)、[13, 26)、[26,38)、[38,50)，层长13、13、12、12。

每层用独立replay RNG均匀抽一个 $k_{e,h}$，权重 $\omega_h = |\mathcal{S}_h|/T$。保存 stratum_id,step_index,sampling_probability=1/size,weight。该采样不查看优势、分数或梯度，在线兄弟仍独立。

$$\mathcal{L}_{\phi,\mathrm{PG}} = -\frac{1}{PNMB_{\mathrm{max}}}\sum_{p,n,m}\mathrm{sg}(A^+_{pnm})\sum_{e\in\tau_{pnm}}\sum_{h=1}^{K_s}\omega_h\bar{\ell}_{\phi,e,k_{e,h}}, \qquad B_{\mathrm{max}} = 3.$$

$$\mathbb{E}\left[\sum_h \omega_h\nabla\bar{\ell}_{k_h}\right] = \sum_h\frac{|\mathcal{S}_h|}{T}\frac{1}{|\mathcal{S}_h|}\sum_{k\in\mathcal{S}_h}\nabla\bar{\ell}_k = \frac{1}{T}\sum_{k=0}^{T-1}\nabla\bar{\ell}_k.$$

因此仍是原始整链 ϕ 梯度的固定 $1/(B_{\mathrm{max}}TD)$ 缩放。T=50时权重为.26/.26/.24/.24，不能统一写1/4；也不再额外除Ks、T或D，不按实际render数平均。动机是少量重放时仍覆盖早、中、后段，不声称某个时段独占某种语义，也不声称对所有梯度分布必然降方差。

同方差Gaussian的每维参考KL为

$$\bar{K}_{\phi,e,k} = \frac{\|\mu_{\phi,e,k} - \mathrm{sg}(\mu_{\mathrm{ref},e,k})\|_2^2}{2Ds_k^2}, \qquad \mathcal{K}_\phi = \frac{1}{PNMB_{\mathrm{max}}}\sum_{p,n,m}\sum_{e\in\tau_{pnm}}\sum_h\omega_h\bar{K}_{\phi,e,k_{e,h}}.$$

分母是 $s_k^2 = d_k^2(-\Delta_k)$。所核Flow-GRPO Kontext路径缺少完整转移方差的 $-\Delta_k$ 因子，按解析式修复。S9

每批只更新一次，直接使用score loss，不需要PPO ratio。$\exp(\bar{\ell}_\phi - \bar{\ell}_{\text{old}})$是完整Gaussian密度比的D次方根，不能当作原密度比。stored logp用于重放一致性。零优势组保留分母；PG自然为零，固定reference KL仍按原定义计算。全批无render时φ无PG/KL，明确跳过该optimizer step并记录no_renderer_action，不能暗中用FM更新来冒充图像RL。Agent-only阶段φ冻结。

13.5 简洁的主损失与固定参考

主RL采用：

$$\mathcal{L}_\theta = \mathcal{L}_{\theta,\text{PG}} + .02\mathcal{K}_\theta, \qquad \mathcal{L}_\phi = \mathcal{L}_{\phi,\text{PG}} + .01\mathcal{K}_\phi.$$

参考是各自SFT结束时的独立冻结adapter，训练中不刷新。两项KL是在当前采样状态上的局部稳定项，不声称包含新策略占据分布变化的完整正则梯度。主路径没有CE/FM replay、全损失κ缩放、按组标准差缩放或八批系数校准。

这是一个明确选择：SFT先建立协议与条件执行能力，RL按真实任务回报调整策略；固定reference控制偏离。若出现经开发集证实的协议或控制遗忘，再单列“加入固定监督回放”的消融/恢复配置，给出相同总训练预算。不能在主实验中悄悄加监督项，然后把全部收益归于RL。

默认θ LR为5×10^{-6}，φ为3×10^{-5}；φ另与10^{-4}做两支各10轮pilot，程序见§15。AdamW、FP32参数与状态、epsilon10^{-8}、weight decay0、global grad clip1。梯度裁剪是极端batch保护，不要求它每轮触发，也不凭“参数变化不超过lr”推断学习效果。

每轮保存优势分布、非零PG组比例、clip前norm、clip比例、有效BA变化、reference KL和任务指标。第1–5轮及此后每25轮，在固定小探针上分开测PG与KL的梯度和输出响应；不每轮为整个batch复制三套参数。输出响应使用old→new的动作分布或归一化速度变化，与同参数重放差异比较。响应超过数值差并不等于任务收益，真正有效性仍由冻结一侧的对照和开发集学习曲线判断。

若连续5个非零PG更新无可分辨输出变化，按顺序检查LoRA覆盖、正确mask、score符号、FP32路径和Adam epsilon是否主导，再做新pilot；必要时另试epsilon10^{-12}并登记配置。不能靠增大KL到任意“目标量级”证明在学习，尤其D=131072时每维KL10^{-3}已对应单转移总KL约131。若整个batch没有优势差异，先检查判据和任务覆盖，后续按预先难度桶增加组合任务；原来零优势组仍保留。

13.6 信用分配的直觉与例子

同一任务的两个根计划各有两条独立后缀。若回报为 $(1.1, .2)$ 与 $(.9, .1)$，两个根的均值为.65与.50，因此根优势为+.15、−.15；同根后缀优势分别为(+.9,−.9)和(+.8,−.8)。根计划按平均后续可执行效果学习；每条后缀中的检查、选择、修复和停止动作，以及它实际执行的每次render，按该根下的独立替代结果比较。

这不是把某个坏像素的责任精确归因到一个token，也不靠图上距离伪造因果奖励。错误节点定位负责把可选修订组织到正确依赖分支；完整轨迹回报负责最终是否满足请求。两侧共享回报、同步采样和更新，但保持各自真实概率及梯度边界。四时间层只安排渲染器反向计算的覆盖，不能把尚未执行的候选算进策略概率。

14. 等价的低显存反向计算

14.1 9B的顺序CFG VJP

对一个选中转移，令该时间层系数 $c = \omega_h/(PNMB_{\text{max}})$，$A = A^+_{pnm}$，$z' = z_{e,k+1}$，$\beta = \beta_\phi$。其损失为 $c[-A\bar{\ell} + \beta\bar{K}]$，转移均值为 $\mu = a_k z + b_k v^{\text{cfg}}$。

先以 no-grad 求当前正负速度与参考均值，计算：

$$g = \text{sg}\left[\frac{cb_k}{Ds_k^2}\{A(\mu - z') + \beta(\mu - \mu_{\text{ref}})\}\right] \in \mathbb{R}^D.$$

再依次建图、反向：

$$L_+ = \sum_d w g_d v^+_{\phi,d}, \qquad L_- = \sum_d (1-w) g_d v^-_{\phi,d}.$$

两次梯度之和等于原损失的一阶梯度；内积使用 sum，不能再 mean。$w = 4$ 时负支必须以 −3 回传。顺序固定为 reference no-grad → current no-grad 两支 → current 正支 forward/backward/释放 → current 负支 forward/backward/释放。两次 backward 中间不得 step、zero_grad 或切 adapter。

该方法增加两次 current no-grad forward，换取一次只保留一个 CFG 分支的激活。日志记录真实 Gaussian loss，不将 VJP 内积数值当作原 loss。初次实施需在小形状下与双支同时 autograd 对比；若最大形状允许直接双支，也可用后者，保持同一个数学目标和独立配置记录。

14.2 27B的全词表KL与head分块

词表248320，不能将每位置KL换成词表子集softmax。lm_head冻结且不含LoRA，因此可以精确地将head与decoder反向分开：

1. 切reference，在no-grad下按§11.1.1装配冻结视觉前缀并调用底层model.language_model得到最后层hidden，仅保存动作预测位置的$H_{\text{ref}} \in \mathbb{R}^{K\times 5120}$。不请求全部层的hidden_states。
2. 切policy并恢复训练状态/冻结白名单，经同一输入装配、完整前缀＋动作language_model forward得到H_θ；保留decoder计算图。microbatch1，$K \le 1024$。
3. 建$\widetilde{H} = \text{detach}(H_\theta)$的需梯度副本。每32个动作位置，用同一个冻结BF16 lm_head计算policy/reference logits，FP32计算log-softmax、全词表KL及该位置的PG。每块backward到$\widetilde{H}$后立即释放大词表张量。
4. 最后一次向量积反向：$H_\theta.\text{backward}(\text{detach}(\partial L/\partial \widetilde{H}))$，通过完整decoder图更新LoRA。前缀的影响仍经过decoder图反传，没有detach前缀。

令$z_i = W_{\text{head}} H_i$，$p_i = \text{softmax}(z_i)$，$q_i$为reference分布，则

$$K_i = \sum_v p_{iv}(\log p_{iv} - \log q_{iv}), \qquad \frac{\partial K_i}{\partial z_{iv}} = p_{iv}\left[(\log p_{iv} - \log q_{iv}) - K_i\right].$$

因此只分块位置、保留全部词表，梯度与完整KL相同。每位置系数直接使用§13根/后缀分母和优势，不再按K平均。PG、KL、CE都可以用自动微分计算head块，不需要手写softmax导数；上式用于验算。

prefix长度为q、动作从0编号j时，预测位置为$q + j - 1$，标签为拼接序列位置$q + j$。completion中的真实EOS照常计分；只按真实response mask删除padding。reference hidden最多10MiB，32位置FP32 logits块约30.31MiB，无需存完整reference词表矩阵。活的policy图期间不切adapter；共同冻结head的参考投影不需要再切回reference。

14.3 9B区域attention的后端与保底

主路径直接调用固定Diffusers已有的transformer.set_attention_backend("_native_efficient")，保留原生Flux2两个processor，传joint_attention_kwargs={"attention_mask": mask}。内部强制PyTorch EFFICIENT_ATTENTION；实际运行要确认使用该kernel。S25

这个选择有明确源码原因：固定PyTorch原生Flash分支拒绝非空attn_mask，而memory-efficient分支的硬件判定允许sm50–sm121，包含5090的sm120。不能只写“用FlashAttention省显存”，也不能让自动选择静默落回完整S^2 math。512最大布局单份32头FP32 score为2.53125GiB，多份中间量可能使9B超过容量。S25

如果目标wheel的efficient kernel不能处理该工作集，先修安装/构建；仍受限时启用确定的等价保底：只按query行分块，每块128行，读取全部K/V，对每块使用非重入checkpoint：

$$O_{a:b} = \text{softmax}\left(Q_{a:b}K^\top/\sqrt{d_h} + M_{a:b,:}\right)V.$$

禁止同时切断K导致softmax归一化改变。bool mask先在算子中转换为允许0、禁止$-\infty$；每行有允许项。保底中的Q/K打分、softmax及概率与V的乘法使用FP32，V在乘法前转FP32，输出再转回BF16；主efficient路径使用库内dtype处理。这个保底保持条件与目标不变，可能更慢；速度按实测报告。再有压力使用训练适用的saved-tensor CPU offload，不用inference-only pipeline offload冒充训练卸载。所有更换在完整stage开始前记录并重做采样/重放一致性门。

15. 训练阶段、采样更新与一致提交

15.1 阶段依赖与启动预算

阶段	参数、数量与启动LR	进入条件
源码/环境/判据门	不训练	§19结构、状态、梯度、概率与资源门；完成判据校准
联结数据	目标8,000对，其中4,000条共享PLAN	public-only PLAN与同一bundle通过配对target的事后兼容筛选
DiT SFT	φ，800 updates，batch12，LR5e−5	同一9B条件接口；target-only FM与mask正确
Actor协议SFT	θ，200 updates，batch20，LR5e−5	PLAN/合约数据；可与DiT SFT并行
固定DiT与修复数据	不更新φ；采样器门＋最多4,800 renders	**DiT SFT完成，policy不merge也不改变精度**；先确定sampler
Actor完整SFT	θ，800 updates，batch20，LR5e−5	共享PLAN及同状态修复/回退/FINISH数据
两轮自身状态纠错	每轮256任务、至多3 renders/任务；各100 Actor updates	当前Actor＋固定DiT SFT，真实已执行纠正动作通过筛选
固定成对reference	复制双方SFT policy adapter，不训练	值相同、storage独立、底座/精度/条件不变
Agent RL热身	θ，100 rounds，φ冻结	当前Actor/Renderer完整轨迹与reference契约
联合LR pilot	φ LR3e−5与1e−4，各10 rounds；θ固定5e−6	从同一个热身checkpoint独立启动
联合RL主段	θ、φ，400 rounds	从共同热身点重启，使用选定LR；同一行为批次同步更新

Actor SFT共1,200 updates、24,000个动作展示；DiT 9,600个样本展示。这些是训练预算，不是独立样本数或收敛承诺。分family验证决定是否过拟合，协议/条件仍未达门时先修数据或接口，不用RL弥补错误标签。需要延长时以200轮为明确新预算段，保留原曲线。

项目	Actor SFT	DiT SFT	Actor RL	DiT RL
LR	5e−5	5e−5	5e−6	3e−5起点；与1e−4比较
global batch	20动作	12图像	P6/N2/M2	同一批轨迹
microbatch	1动作	1图像	1动作	1图像×1转移
AdamW β	(.9,.999)	相同	相同	相同
epsilon	1e−8	相同	相同	相同
weight decay	.01	.01	0	0
global norm clip	1	1	1	1
主正则	无额外KL	无额外KL	.02×reference KL	.01×reference KL

各SFT阶段前5%更新warmup，再cosine到起始LR的10%；新阶段重建optimizer/scheduler，模型参数连续。SFT结束冻结reference时重建RL optimizer。Agent阶段前10轮warmup；进入joint保留θ Adam历史，φ首次启用时初始化其Adam；两侧joint LR再warmup10轮后固定。pilot直接用比较LR，不让十轮全处于低LR暖启动。每25轮固定64个开发任务检查，最大3 renders/任务。

15.2 20轮联合pilot

两支均从同一100轮热身checkpoint及θ optimizer开始；φ拥有相同SFT adapter但各自新建optimizer。A用φ LR3e−5，B用1e−4，θ均5e−6，每支10轮新采样/更新。跨配置采用配对任务序列与外生seed；每一配置内部根计划和后缀独立。每支结束在相同64开发任务上评估。

选择先满足数值/协议/资源门，再比较任务完成、保护与视觉质量；差异不足以明确区分则选3e−5。没有PG响应时先查梯度与判据，不以任选KL目标决定学习率。数值正常且图像有响应但收益未出现时，观察学习曲线并按预设预算延长，不声称十轮证明了最终优劣。

pilot最大训练render为20×72=1,440，末端开发2×64×3=384，合计1,824。正式joint从共同热身点重新启动，不拼接两支权重或将pilot选优收益计作测试成绩。固定β无需额外八批校准。

15.3 一个联合更新周期

```
snapshot = begin_transaction(policy_adapters, optimizers, rng, data_cursor)
versions = freeze_and_ack_all_workers(snapshot)
batch = collect_complete_groups(P=6, N=2, M=2, versions=versions)
assert_complete_groups_and_public_private_separation(batch)
assert_replay_contract(batch)
root_adv, suffix_adv = hierarchical_rloo(batch)
zero_policy_gradients()

for action in batch.unique_roots_and_actual_suffix_actions:
  # reference hidden first; policy full graph; head chunks; decoder VJP
  backward_controller_pg_kl(action, root_adv, suffix_adv)
for render in batch.all_executed_renders:
  for step, weight in stratified_steps(render.T, strata=4):
    backward_cfg_vjp(render, step, time_weight=weight)

sum_allreduce_actor_policy_grads()
sum_allreduce_renderer_policy_grads()
assert_finite_on_all_ranks()
clip_global_policy_norms(1.0)
wait_both_components_ready()
step_active_optimizers_once()
validate_small_update_probes()
write_both_checkpoint_payloads_and_hashes()
write_COMMITTED_manifest_last()
publish_new_pair_and_wait_ack()
```

Agent-only不执行ϕ反向/step。全批无render时ϕ optimizer不step，事务仍登记其旧版本。各local loss已经含全局分母；手动SUM后不再除world size。空rank提供零梯度并参加归约。若以后改用默认平均DDP，必须在local loss补world-size因子，不能双重平均。两个组件更新期间不产生下一批rollout。

15.4 reference、训练状态与事务

reference 先 no-grad 计算，切 policy 后设置 decoder/ DiT 为 train、冻结视觉塔为 eval、dropout0、use_cacheFalse、非重入checkpoint。所有policy图backward完成前不切adapter、step或清梯度；BN/encoder/judge始终冻结。set_adapter会改requires_grad，因此每次切回后恢复明确白名单；optimizer参数列表只包含policy。

checkpoint保存双方policy/reference引用、optimizer/scheduler、RNG、数据游标、行为版本、量化/条件/判据manifest与batch ID。双方文件和hash完成后最后写COMMITTED；一侧失败则恢复双方完整状态，不能仅退版本号或只恢复权重。S11

固定16个动作视图与16个不同时间/布局转移作轻量发布探针。动作位置平均old→new KL>.1 nat，或DiT每维平均old→new KL>.01时拒绝发布、双方回滚、LR减半，至多重试两次；仍异常则停止该更新诊断。阈值是防止破坏性更新的工程上限，不是理论信任域，也不是必须达到的学习目标。每位置/每转移最大值同时报告。

只有精确恢复到采样时的双方参数和optimizer时才可重用该batch；否则重新收集完整组。所有重试、未提交计算和失败pilot纳入成本。最终收益由§20的任务比较给出。

16. 失败、重试、零信号和终止

情况	明确处理
非法 JSON/引用/几何/动作状态	原 token 保留；第一次反馈，第二次协议失败 −1
合法生成但效果差、修复引入回归	正常低奖励；保留全部调用和 score
长度截断	finish_reason=length，真实 token 全部保留；解析失败按协议处理
内容含混、检测/VLM 冲突	semantic unknown，固定要求分母，软分为 0
RPC 超时/校验失败	同作业、同输入、同版本、同 seed 重试最多两次
服务仍不可用	保持 batch 未完成，停止更新并补齐完整组；不只训练成功兄弟
可复现 NaN/未知 OOM	停止采样事务、恢复最后提交，检查数值/内存；不转换为低奖励图
梯度非有限	两侧均不 step、不推进 scheduler，保留诊断数据
全部 advantage 为零	PG=0；固定reference KL仍按定义计算；记录PG为零，不虚报任务学习
全批没有 render	ϕ 的 PG/KL 为空；该轮ϕ不step，不加入未声明的FM
revision/行为版本/条件 hash 不一致	拒绝 replay，查明原因后完整重收集

初始执行超时为控制器900秒、render1200秒、单检查300秒（排队时间单独记录）；首轮服务 profiling 后以 max(初始值,3×P99) 固定新的超时配置。超时和排队延迟不进入策略 reward，避免机器调度造成分支耦合。中断统计列出已消费生成、失败作业与未提交 batch，不能隐藏额外计算。

若zero-advantage比例>80%连续25轮，或连续5个有PG更新无法分辨输出响应，暂停当前更新段，按“判据分辨率→分组独立性→token/梯度接口→数据难度与探索”的顺序排查。原完整组不删除；重配以新stage/config登记。协议非法和内容未知可成为学习信号，设备/服务故障不能伪造成负奖励。

17. 两台服务器的职责、资源与默认配置

17.1 GPU职责：完整副本、阶段切换、本机归约

GPU	常驻组件	具体职责
A0、A1：各48GB A6000	各一份27B NF4底座＋policy/reference LoRA	每卡同一时刻一个完整动作请求；采样与训练分阶段；更新microbatch1，本机SUM梯度
A2：48GB A6000	冻结Qwen3-8B文本编码器＋FP32 VAE	条件编码及最终latent解码；文本/图像工件缓存
A3：48GB A6000	冻结32B NF4判据＋一次一个视觉工具	公开CheckSpec/检查与私有终评分队列；工具按需装卸；判据microbatch1
B0、B1、B2：各32GB 5090	各一份9B BF16 DiT＋policy/reference LoRA	三个生成worker；更新时一图一转移，顺序CFG VJP，本机SUM梯度

A6000与5090的标称显存分别为48GB和32GB，计算能力为8.6与12.0；不将显存相加当作单卡容量，不假定已有NVLink桥、P2P或某种网速。S17 跨机仅传条件、最终latent、图像/证据与版本消息；**不做跨机梯度同步**。每种策略的在线采样和重放使用同一类GPU、同一量化制品和kernel配置。

离线PLAN教师在A0/A1使用同一冻结27B；修复数据阶段也可以在卸载Actor后，把空闲A6000临时用于9B推理或判据副本。先测队列瓶颈再分配，不能把同一卡同时计入两种并发资源。同一配对候选组固定设备类型与backend。独立人工/官方基准评估在训练暂停的时段进行。

参考策略通过**切换至独立SFT reference adapter**计算，之后切回policy并重建其梯度白名单；不通过disable_adapter得到未SFT底座。一次policy计算图存活期间不切adapter。A2只实例化encoder/VAE，不调用会额外加载DiT的整套bundle构造器。S5 S6

17.2 显存的可复核预算

以下均为根据真实shape与dtype计算的静态预算，**不是实测峰值**。定义$1\ \text{GiB} = 2^{30}$ bytes、$1\ \text{MiB} = 2^{20}$ bytes。

对Q个NF4参数、U个BF16非量化参数，双量化存储近似为

$$M_{\text{base}} = \frac{Q}{2} + \frac{Q}{64} + \frac{4Q}{64 \cdot 256} + 2U \quad \text{bytes.}$$

依次是4bit载荷、一级scale的8bit载荷、二级FP32 scale、非量化权重；每个tensor少量codebook、对齐和allocator另外计。FP32 norm的增量单列。可训练参数及其梯度、Adam双矩、冻结reference均FP32，主常驻量为$20N$ bytes；这不是只算一份LoRA。

项目	静态量与含义
27B量化底座	$Q = 24,326,963,200, U = 3,029,765,360$；约17.331GiB，norm精度增量约1.54MiB
27B policy＋grad＋Adam m/v＋reference	$20 \times 116,727,808$ bytes＝2.1742GiB；底座加这些约19.51GiB/卡
27B full-attention KV	$16 \times 2 \times 4 \times 256 \times 7168 \times 2$ bytes＝448MiB，一次动作一份
27B GDN状态	recurrent $48 \times 48 \times 128 \times 128 \times 4$＝144MiB；BF16 conv状态3.75MiB
27B checkpoint层输入	$64 \times 7168 \times 5120 \times 2$＝4.375GiB；不代表全部activation
27B head分块	32位置完整词表FP32 logits＝30.3125MiB；不物化7168位置全词表
最大单个NF4反量化矩阵	$17408 \times 5120 \times 2$＝170MiB；反向工作区另计

项目	静态量与含义
9B BF16底座	$9,078,581,248 \times 2$ bytes=16.9102GiB
9B policy+grad+Adam m/v+reference	$20 \times 31,981,568$ bytes=0.5957GiB
9B checkpoint块输入	$32 \times 4608 \times 4096 \times 2$=1.125GiB，仍不含全部activation
9B bool attention mask	4608^2 bytes=20.25MiB
若误走math attention	单层32头FP32 score为2.53125GiB；backward和多份中间量尚未计入
A2：8B encoder / FP32 VAE	约15.2564GiB / 0.313GiB，另计编码activation与缓存
A3：32B NF4判据	量化31,205,621,760、非量化2,151,768,304参数，约19.00GiB权重；没有LoRA/optimizer

目标机启动门：Actor训练卡峰值reserved≤42GiB，DiT卡≤28GiB，A2/A3也保留至少6GiB设备余量；先32次最大布局完整周期，再100次稳定循环。记录allocated、reserved、CPU RSS与服务队列。余量门是工程目标；在实际模型上执行前不能写成“已经可放下”。

内存优先级明确：每worker取消并发图；启用块checkpoint与§14顺序VJP；DiT显式_native_efficient；若该kernel实机不通过，使用已验证的query行分块+checkpoint；仍超限再考虑CPU saved-tensor offload。不能关闭区域mask、去掉负CFG支或减少reference精度却仍报原配置结果。768分辨率不是本主配置：最大序列增至8448，仅单层math score即8.5078GiB，必须独立验收。S2 S25

17.3 一轮的真实计算与通信

$P = 6, N = M = 2$产生24条episode、最多72次render。一个[1024,128] FP32 latent为0.5MiB；50步的51状态链为25.5MiB，整轮最大1836MiB，保存在B的CPU/NVMe。B只把每图最终0.5MiB发A2解码，最多36MiB/轮。

一个[512,12288] BF16文本块为12MiB。三个正块加两个参考latent共36.5MiB/render；负空串块按encoder版本缓存，bool mask在B依据几何manifest重建。上限A→B为2628MiB/轮，实际重复条件经内容缓存减少传输。网络带宽与调度实测，不凭卡数估墙钟。

Actor梯度445.28MiB/rank，DiT梯度122MiB/rank。本机ring SUM的典型每rank通信量为$2(W-1)/W$倍，分别约445.28MiB和162.67MiB；具体collective算法由实际环境记录。行为old使用事务开始时的policy值，CPU保存小adapter/optimizer快照；不另驻留一套old大基座。

采样配置	轨迹 / 最多render	rollout DiT forward	replay forward / backward
主配置T50、Ks4	24 / 72	7200	1728 / 576
通过质量门的T28、Ks4	24 / 72	4032	1728 / 576
通过质量门的T20、Ks4	24 / 72	2880	1728 / 576

公式为$F_{\text{roll}} = PNMB_{\max} \cdot 2T$；每轮最多$72 \times 4 = 288$个重放转移，每转移包括current/reference双支与current双支VJP，共6次forward、2次backward，尚未计checkpoint重算、探针和Actor。四时间层采样不等于重放整条50步链；全链仍需保存以还原被抽位置。

根动作共享后的最大生成token数为

$$[PN + PNM(H_{\max} - 1)]L_{\max} = [12 + 24 \times 9] \times 1024 = 233,472 \text{ tokens/round}.$$

500正式轮的116,736,000是极端上界，不是期望token数。大模型成本必须包含这些逐token决策、完整prefix replay和judge；不能只按9B图像forward排期。

17.4 包含数据、pilot与判据的总账

一条主训练路径	最大render数
修复、注入及两轮自身状态纠错	6336
采样器初筛，含两种后备配置	768
20轮LR pilot+末端开发	1824
Agent100+joint400正式轮，500×72	36,000

一条主训练路径	最大render数
每25轮64任务开发，20×64×3	3840
小计	**48,768**

这里没有额外八批系数校准，也没有RL中未声明的CE/FM replay。800次DiT SFT与1200次Actor SFT是训练forward/backward，另计；最终benchmark、多基线、多训练seed、可选控制、原始数据核验、额外重试与追加实验也另计。600-render数据pilot是6336内部子集。joint400轮最多重放115,200个转移；非零PG转移数必须实际报告。

判据账。 令K_c, K_g为公开/私有原子数，$b \le 3$为实际render数。§9第一模板始终运行，第二模板仅在固定路由需要时运行，因此

$$K_c b + K_g \le N_{\text{query}} \le 2(K_c b + K_g), \qquad N_{\text{answer sequence}} = 2N_{\text{query}}.$$

$K_c = K_g = 12, b = 3$时，一条轨迹48–96个逻辑二选一query、96–192条答案候选序列；24条轨迹1152–2304个query。6个新的编辑source若双通道均未缓存，再增加144–288个query。INSPECT、CheckSpec分解和被分页的原子按真实数量另计。

6336张修复数据图若都接受双通道各12原子检查，共152,064–304,128个query；原始最多12,000对若source/target各12原子，则288,000–576,000个query。可靠人工标注、规则检查和缓存可以减少实际模型调用，账本必须记录采用了哪种证据。最多24,000次公共PLAN教师提案及额外96条最多192次提案与这些query分开统计；1024条合约恢复可由规则构造。修复教师提案、刷新提案另按§7实耗记录。CheckSpec每个唯一请求首次一次、格式修正最多一次，$N_{\text{decompose}} \le 2N_{\text{unique request}}$。

这个账揭示了需要首先实测的瓶颈：A3判据队列和27B逐token生成可能比9B训练更慢。离线按时段增加判据副本，在线维持固定配置；不能以改变检查标准来隐性压低成本。

17.5 主存、存储与排期

主存起点建议A可用≥128GiB、B≥64GiB，舒适配置A256/B128GiB；SSD建议A≥1TB、B≥2TB空闲。这些是**待盘点的需求**，不假定用户已经具备。OmniEdit只流式取得所选样本，不下载TB级全集。S13

8,000对数据平均两个文本块约187.5GiB，可用两机各64GiB磁盘LRU，按原文及固定encoder重新生成。27B原始checkpoint约55.56GB、序列化NF4约18.6GB；32B判据原始约66.7GB、NF4约20.4GB；9B约18.16GB、8B encoder约16.38GB，属于磁盘数据，不应加进GPU常驻量。

512^2 Actor processor的FP32图像tensor为6MiB。正式36,000张生成图的tensor上界210.94GiB，24,000个主动crop上界140.625GiB；源图、参考和离线图另计。按图像/processor hash去重，完整RL实际视图tensor在当前阶段保留，SFT只保存原图、IDs、processor版本和有限缓存。

500轮完整latent链上界896.48GiB；Agent100约179.30GiB、joint400约717.19GiB。阶段验收后按预先登记的归档策略保存全部manifest、图像、checkpoint，保留分层1%完整链及最近两轮恢复链；不让多seed实验无界累积。若B只有1TB，则必须阶段归档或外置存储，不能承诺一盘容纳所有中间态。基座只有固定版本一份，checkpoint只存adapter、optimizer与引用。

实际排期程序：每类服务20次warmup＋100次计时，再跑10轮真实依赖队列，记录p50/p95/P99、峰值显存、每轮token/render/query数、集合通信与事务时间。按这些测量外推完整预算；不根据理论TFLOPS或未经运行的“每图若干秒”给出天数保证。

17.6 集中默认配置

```
protocol: dag-agent-v3
canvas: [512, 512]
train_max_eval_atoms: 12
check_atoms_per_batch: 12
max_entities: 16
max_active_regions: 2
max_source_images: 1
max_appearance_images: 1
episode: {max_actions: 10, max_renders: 3, max_inspects: 2, max_reads: 2}
feedback:
 public_source: frozen_request_only_CheckSpec
```

```
  reveal_after_first_valid_plan: true
  gold_visible_to_actor: false
  private_reward_timing: terminal_plus_source_baseline
  read_nodes: {max_nodes: 16, max_tokens: 1024}
 actor:
  model: Qwen/Qwen3.8-27B
  class: Qwen3_5ForConditionalGeneration
  quant: nf4_double_quant
  compute_dtype: bfloat16
  policy_reference_dtype: float32
  recurrent_cache_dtype: float32
  max_view_images: 4
  input_tokens: 6144
  output_tokens: 1024
  enable_thinking: false
  preserve_thinking: false
  temperature: 1.0
  top_p: 1.0
  top_k: 0
  min_p: 0
  repetition_penalty: 1.0
  lora: {r: 16, alpha: 32, dropout: 0.0}
  one_request_per_worker: true
  fresh_cache_each_action: true
  lm_head_positions_per_chunk: 32
 judge:
  model: Qwen/Qwen3-VL-32B-Instruct
  quant: nf4_double_quant
  input_tokens: 8192
  max_images: 2
  second_template: fixed_uncertainty_conflict_hardtype_route
 sft:
  actor_global_batch: 20
  phase_counts: [5, 7, 5, 3]
  phase_weights: [0.25, 0.35, 0.25, 0.15]
  action_token_mean: true
  renderer_global_batch: 12
  aligned_target_pairs: 8000
  shared_actor_plans: 4000
  text_dropout: 0.1
  repair_data_after_renderer_sft: true
  repair_render_cap_with_refresh: 6336
 renderer:
  model: black-forest-labs/FLUX.2-klein-base-9B
  text_hidden: 12288
  dit_hidden: 4096
  steps: 50
  efficient_step_candidates: [28, 20]
  require_sampler_quality_gate: true
  cfg: 4.0
  sde_eta: 0.3
  stochastic_steps: all
  state_dtype: float32
  model_dtype: bfloat16
  policy_reference_dtype: float32
  text_block_tokens: 512
  attention_backend: _native_efficient
  lora: {r: 16, alpha: 16, dropout: 0.0}
 rl:
  tasks_P: 6
  roots_N: 2
  suffixes_M: 2
  sampled_steps_Ks: 4
  step_sampling: contiguous_strata_one_each
  step_weights: stratum_size_over_T
  actor_fixed_denominator: 10240
  actor_lr: 5.0e-6
  renderer_lr_default: 3.0e-5
  renderer_lr_pilot: [3.0e-5, 1.0e-4]
  pilot_rounds_each: 10
  updates_per_collection: 1
  ppo_ratio: false
  gradient_reduce: sum
  beta_actor: 0.02
  beta_renderer: 0.01
  supervised_replay: false
```

```
 max_global_grad_norm: 1.0
 agent_only_rounds: 100
 joint_rounds: 400
runtime:
 compile: false
 microbatch: 1
 activation_checkpoint: non_reentrant
 sequential_cfg_vjp: true
 cross_machine_gradient_sync: false
 retry_same_job: 2
 seed_streams: independent
```

完整revision、wheel/量化/adapter hash、模型许可取得状态、sampler、reward、数据和验收记录进入lock manifest。候选步数/LR按既定开发程序选定后冻结，不边训练边改变算法定义。

18. 有明确接口的扩展

18.1 真正的depth/pose控制

主配置已经使用图像、layout、区域mask、实体参考与检查证据。深度图、姿态图需要模型学会相应语义，不能塞进appearance slot就宣称获得控制。需要时新增小型残差adapter及配对监督；它是同一DAG中的一种控制节点，不取代整体架构。

一个目标latent token对应16×16 canvas像素。深度采用有效值5%/95%分位归一化的相对逆深度，近=1、远=0，裁到[0,1]；无效处置0并有valid通道，常量深度置.5。两个通道pixel-unshuffle得到512维。Pose用COCO17关节热图＋valid共18通道，热图标准差8像素、峰值为置信度，缺失关节置零；unshuffle得到4608维。坐标先应用同一canvas变换。

每种控制得到[B,1024,d_in]，经Linear(d_in,64) → GELU → Linear(64,4096)得到[B,1024,4096]，只加到x_embedder输出的前1024个target token；source与appearance参考段残差为零。两种控制同时存在则相加；缺失走明确零旁路。第一层随机初始化，第二层权重和bias为零，不再叠加一个同样零初始化的乘法gate。

含bias的参数量为$d_{\text{in}} \cdot 64 + 64 + 64 \cdot 4096 + 4096$。depth为299,072、pose为561,216，共860,288；扩展生成侧可训练参数为32,841,856。按policy、梯度、Adam双矩和reference合计20bytes/参数，额外约16.41MiB静态存储，不增加token序列长度。

数据至少2,000对，来源为真实人工控制/标注或可核验合成场景，family分离。target-derived监督只能作为离线loss/筛选；作为条件使用的depth/pose必须在训练任务中显式定义为用户提供或公开工具产生，不能测试时凭隐藏目标补入。控制SFT默认400 updates、batch12、LR5e−5，沿用§8 FM，整组文本dropout.1、整种控制dropout.1；控制在CFG正负两支保留。

200个隔离任务检验深度成对前后次序准确率与PCK@.05：有效关节误差≤.05×512像素为通过，应该出现但未生成的关节计失败，真实遮挡按标注单列。至少相对“同一文本、无该控制”有可识别的控制响应，且质量/身份不实质下降，才进入RL。

新增MLP属于ϕ，SFT完成后复制独立冻结control_adapter_ref；policy/reference一起切换LoRA和控制MLP。新分支重新登记SFT参考点，从该点开展RL，不在主实验中途改变reference。S2 S5

18.2 可变推理预算和替代生成目标

主配置显式关闭自由thinking，保留PLAN与修订字段中的必要说明。若增设thinking预算，所有实际生成思考token都进入score、长度及成本；raw tokens完整保存，终止/截断按同一规则处理。不能只训练最终JSON而忽略决定它的已采样思考。先用固定开发任务比较质量/总token/时间，再决定是否采用为新配置。S1 S3

DiffusionNFT提供另一种生成侧后训练目标，值得作为后续独立分支参考，但不能在没有推导与同预算验证时把它与当前Gaussian score同时堆进主损失。S16 主方案已经有可核验的联合分布和两个梯度通道，先完成这些通道的有效性比较。

同理，不默认增加影响预测器、额外价值网或连续“隐语”桥。需要新增时，以其解决的实际瓶颈、输入/输出、额外训练数据和成本明确立项；DAG的错误定位与分支修订已经由公开证据、依赖闭包和Agent动作完成。这里是实施顺序安排，不对课题方向或可研究内容设限。

19. 实施模块、依赖顺序与集中验收

19.1 按这个顺序实现

顺序	计划文件/模块	产物与完成条件
0：环境和模型锁	configs/lock.json, runtime/probe.py	驱动、wheel、拓扑、模型/量化hash；两GPU架构算子探针
1：状态与工件	schema/, dag/, store/	不可变revision、槽类型、循环检测、分支与SELECT，不依赖大模型即可验证
2：27B worker	models/qwen35_actor.py, models/fp32_linear_cache.py	NF4白名单、496个LoRA目标、模板/视觉/EOS、每动作cache及RoPE隔离
3：9B编解码	models/klein_codec.py, models/klein_renderer.py	8B encoder、VAE/BN、112个LoRA目标、DiT-only worker、efficient attention
4：条件编译	conditioning/compiler.py, conditioning/geometry.py	文本12288维、目标/源frame、引用角色、bool mask、4轴IDs与bundle hash
5：采样和轨迹	sampling/flow_sde.py, trajectory/	唯一CFG velocity、FP32完整链、raw action IDs、独立随机流与幂等重试
6：检查与数据	checks/public_spec.py, reward/private_eval.py, data/aligned_pair.py	DTO/存储隔离、判据校准、public-only配对PLAN、family分区
7：成对SFT	train/agent_sft.py, train/fm_loss.py, data/state_bundle.py	DiT与协议预热→sampler门→真实修复→Actor完整/纠错SFT
8：reference	models/reference.py	同底座独立SFT adapter，无merge/requant；两框架正确API与梯度白名单
9：Agent RL	train/hierarchical_pg.py, train/actor_head_vjp.py	根/后缀分组、全词表KL、完整prefix梯度、100轮学习曲线
10：联合RL	train/stratified_replay.py, train/cfg_vjp.py, train/transaction.py	双score通道、四时间层归约、两侧一致提交、pilot及400轮主段
11：评测	eval/official_adapters/, eval/paired_stats.py	同任务/预算/seed主比较、消融与独立人工审计

表中是未来系统实现清单，本轮只编写研究文稿和轻量验证脚本，没有实现这些研究模块或启动训练。每步已有明确的前置产物，实施者不需要自行决定“哪个模型先训、哪个输出进入哪个模型”。

19.2 八组验收，把正确性问题集中解决

门1：结构、算子和量化。 在真实设备上断言27B的400个NF4模块、496个LoRA目标、116,727,808参数；9B的112个目标、31,981,568参数。确认完整checkpoint加载，9B不得用零tensor补missing weights；其gated快照取得后核验与公开结构的差异。Norm、GDN state、量化载荷、LoRA与encoder dtype逐项检查。原始LoRA零增量应复现原底座，SFT复制reference后应复现SFT policy；两者storage独立。

在训练前固定128个公开开发视图，比较NF4和BF16 27B的动作合法率、要求覆盖、视觉身份/几何题。BF16仅在离线时暂用两张A6000切层推理，测完恢复主布局，不用两卡BF16训练。若NF4有明确集中退化，按误差位置扩大不量化模块白名单、重算资源和重新过门；不默认为“更小模型更安全”。量化质量是待验证项，不从参数规模推断效果。

门2：视觉、缓存与概率。 固定0/1/2/4图、长/短prefix、两个EOS、图→纯文本→图、分支切换case。保存实际processor产物和位置；采样记录raw tokens与logp，同一行为版本full replay重算，随后打开train/dropout0/checkpoint重算。初始容差使用§6.6的mean abs logp≤.01nat、p99≤.05nat、抽样位置全词表KL≤1e−3；同时报告max，检查大差值原因。确认GDN recurrent FP32、conv/KV BF16，每动作独立cache，prefix梯度不被detach。超门先修实现与kernel一致性，不能更改stored logp掩盖差异。

门3：损失、梯度与归约。 先在CPU小模型验证，再在真实模型小布局验证。

- 对$z = \phi + \epsilon, \epsilon \sim N(0,1), R = z$，score期望梯度为1；独立兄弟RLOO应在3个估计标准误内，复用同一噪声导致差值为0应被反例捕捉。对$r \sim \text{Bernoulli}(\text{sigmoid}\,\theta), z = \phi + r + \epsilon, R = z^2$，检查$\partial_\phi J = 2(\phi + p)$及$\partial_\theta J = p(1-p)(2\phi + 1)$。
- 小T枚举分层抽步，按层长/T的期望等于全时间平均；不等rank切分和空rank的SUM等于单进程。token/sample mask、固定$C_\theta, B_{\text{max}}, T, D$不重复除。

- head分块VJP与直接全词表KL/PG反向比较；CFG VJP与同时双支反向比较。FP32相对梯度误差≤1e−4，真实BF16≤1e−2且cosine≥.999。正负支、reference切换单独覆盖。
- 真实目标token含EOS有CE，system/user/tool/旧错误/padding没有CE；policy目标参数有梯度，base/visual/encoder/reference均grad为空。RL初始不是新零B，因此不把SFT后A梯度必然为零当预期。

门4：连续策略与控制真实进入网络。 复算sigma严格下降至0、所有$s_k > 0$、SDE经验mean/variance与解析核一致，Gaussian KL使用实际s_k^2。FP32小模型重放相对误差≤1e−5；真实BF16 velocity重放均值误差除以s_k的RMS≤1e−3为起点。保存的最终z_T直接解码，不能用另一条ODE终图领SDE奖励。

先将无区域、单源参考路径与官方9B pipeline对齐；区域路径检查0/1/2区域、重叠区、两个同类对象交换绑定、source/appearance交换槽、source与target位置不同、第二参考段是否作用于指定对象。用已知Q/K/V检查单层允许边，不能要求多层模型完全没有间接信息传播。对布局/绑定做扰动，bundle、attention输出及生成响应应随之改变。§12同条件sampler质量门通过后固定训练/测试同一采样器。

门5：DAG与公开信息契约。 覆盖漏项修复、祖先修订的后代失效、无关工件缓存复用、整图观察变化使依赖决策失效、SELECT恢复manifest与实际source、过期候选拒绝、retry仅换seed、一次非法根在各后缀继承且动作≤10、原source直接FINISH的零render轨迹。终局仅交付指定图，不能自动挑私有奖励最高图。

固定公开输入、模型与RNG，打乱隐藏EvaluationSpec顺序、答案、ID、benchmark字段或target；终止前AgentView bytes、token、公开调用、bundle hash和生成图必须不变，只允许私有终评改变。公开分页只查询PublicEpisode投影。SFT教师输入等于同状态ActorView；私有FM权重mask不能进入条件。judge校准与SFT每桶100条人工抽查同时完成；关键标签错率≤5%，1024token能容纳合法动作，配额达成率据实报告。

门6：最大工作集与吞吐。 按§17运行32次最大布局完整forward/backward/step及100次稳定循环；A≤42GiB、B≤28GiB，内存不持续增长。确认mask进入efficient kernel；保底query块必须与full attention数值/梯度一致。对27B、9B、encoder、judge分别计时，再测真实10轮队列。若静态可放但真实OOM，先执行§17的明确内存处理顺序。

门7：更新、发布和恢复。 两侧均应有非零任务PG及可分辨的输出响应；同时报告reference KL、参数变化和真实成功率。故障注入覆盖重复RPC、损坏工件、judge超时、空rank、一个optimizer先step另一侧失败、checkpoint半写、发布前断连；恢复后双方参数、Adam、RNG、游标和版本与最后COMMITTED一致。没有完成完整组则不更新。

门8：任务效果。 完成§20同预算B2/B3/B4/B5，报告提升/退化的置信区间和类别；至少能回答SFT是否帮助合法计划/条件执行、RL是否改善真实决策、生成器是否收到有效回报梯度、联合是否优于对应单组件。门8的结果是实验结论，不预先承诺一定改善。效果不足按失败类型修数据、控制或优化，保留完整曲线与成本；不拿loss下降替代研究目标。

19.3 完成标准的层次

“可以运行”以门1–7的结构、数值、资源、恢复通过为准；“有实质收益”以门8及独立评价为准。CPU公式检查只能关闭公式/归约层面的疑问，不能替代27B/9B真实GPU验收。验收记录统一保存最小输入、预期、版本、实际结果与修复diff，避免把同一个问题在各章节重复扩张成新的研究模块。

20. 基线、消融、统计与问题排查

20.1 主比较与公平预算

主比较全部使用同一Qwen3.8-27B NF4控制器、同一Klein-base-9B和相同工具。不能把v2的4B结果与v3直接相减后归因于算法；模型容量比较另设独立实验，接口/数据/预算保持一致。

ID	控制器	渲染器	用途
B0	固定请求/固定流程	原始Klein	底座与生成成本参照
B1	固定流程	DiT SFT	单独检验条件SFT
B2	Controller SFT＋完整DAG	DiT SFT	双侧SFT后的共同起点
B3	Agent RL＋完整DAG	固定DiT SFT	单训控制器
B4	固定共同Agent热身checkpoint＋DAG	DiT RL	同一起点后仅更新生成器；纯双SFT起点另名B4-SFT
B5	联合RL＋完整DAG	联合RL	主系统

另设同预算固定prompt重写、顺序修复、best-of-3和“分别训练后拼接”对照。best-of-3只使用CheckSpec选

图：先按已知通过项数、再按公开固定分母软分、再按用户公开保护约束得分排序，仍并列取最早生成图；不可用终评真值选；分别训练后拼接的总训练render/forward预算与联合训练对齐。B0/B1可以报告单次生成和三次预算两个点。所有方法报告render数、DiT forward数、输出token、GPU秒、墙钟、实际缓存命中与逻辑动作成本，不能只选有利的成本轴。

最小完整主比较从共同100轮Agent热身checkpoint各续训400轮θ-only、ϕ-only、joint；三支P/N/M/T、任务序列和最大render预算相同，直接隔离同一起点之后的更新方式。这里的ϕ-only支明确带有共同的Agent热身，不能冒称从未训过Agent。另可从纯双SFT起点分别运行500轮θ-only、ϕ-only，对照100＋400联合路径，作为总预算比较；这组额外实验单列成本，不隐藏在主系统500轮中。

一组共同热身＋三支续训最多(100+3×400)×72=93,600训练renders/训练seed；三个训练seed上限280,800，另有数据、pilot、评测。资源执行顺序是先完成一组seed的闭环和主比较，再完成另外两组；数据与冻结编码可共用，模型/optimizer/RNG不混用。若只完成第一组，报告当前结果及不确定性，不把它写成三seed结论。

主评测每任务只运行一条受预算约束的轨迹。训练的N×M分层采样不是默认推理时best-of-4搜索；若另测推理搜索，独立标明搜索和选择成本。最终评分只评实际SELECT/FINISH交付图，不能用轨迹内oracle best image替换。

20.2 必要消融

- **SFT对齐：**共享public PLAN/compiled bundle对比独立构造两侧数据；两组使用相同原始image pair、family分区、教师调用及修复render预算，报告实际可用数和几何相容率。这样检验“学提出的条件”和“学执行的条件”是否需要一致。
- **SFT作用：**无Controller SFT、无DiT SFT、都无SFT；成功示范、加失败修复、再加回退/停止三个数据消融；原token均值、单动作均值、phase＋动作均值三个归约消融。对齐family、验证render与训练token/更新预算，报告真实重复率。检查短停止动作准确率、回归率、条件执行率和最终成功，不只看loss。
- **联合训练：**只训θ、只训ϕ、同时训、分阶段独立训练后组合；加两侧梯度norm/更新量，证明主系统两侧确实收到任务回报信号。
- **DAG：**相同观测与工具预算的顺序历史、只记录DAG不用于决策、去观察依赖、禁祖先修复、每次全分支重算。分别测成功、回归和实际缓存收益；DAG优势不预设为局部DiT算力节省。
- **多模态条件：**仅文本、布局＋mask、加入身份参考、source/target共用mask、去参考实体绑定、关闭区域attention。所有版本保持相同评价要求。
- **信用与奖励：**平坦episode信用对比分层；Ks2均匀作为成本—效果点；固定Ks4、相同轮数与重放转移总量比较均匀抽步和四层覆盖，检查梯度方差、分时段响应及最终指标。去min项、去保护项、仅终图软分。共享噪声导致有偏估计的实现只作为数值反例，不作为推荐训练方法。各奖励定义重新报告实际量纲，禁止修改要求分母。

先在固定开发子集执行接口性消融，完整主对照进入正式评估。统计显著性和效果大小都报告，不用单个seed挑选“最好配置”。

20.3 数据集与统计协议

自建500个隐藏诊断任务分为五类各100：规划覆盖/漏项、实体身份/关系绑定、局部编辑/保护、祖先错误传播、多分支修订/回退。每类分自然错误与受控注入，并分别报告；注入标签不进入Agent或judge输入。开发200任务、校准600任务、诊断测试500任务按family隔离；公开benchmark不参与奖励调参。

官方测试并行报告：GenEval按官方类别宏平均；GenEval2使用官方800条、Qwen3-VL-8B和明确的--method soft_tifa_gm，每prompt问答软分几何均值后跨prompt平均×100；MagicBrush报告全部turn与最终turn，并使用其官方DINOv1指标。S12 S14 官方GenEval2实际将可接受答案变体的首token概率相加，并非内部完整Yes/No+EOS序列归一化；保持其原算法，另记录重复token ID的sanity检查，不能静默修正后继续叫官方分数。官方README的Transformers4.57环境独立运行，模型revision固定；内部32B NF4判据、DINOv2保护分与本文CS分别命名。S14公开test在2026年已可用的事实已重新核对，不沿用旧材料“没有test”的描述。

MagicBrush建立两条轨：独立编辑每turn读取官方该turn source，写inde_*并统计全部turn；迭代编辑从session首图开始，后续turn以前一turn实际交付图为source，写iter_*并统计最终turn。每turn重新给10动作/3render预算，保留session级来源，不把独立轨输出冒充迭代结果。默认mask-free编辑仅输入source＋instruction；包中target、mask或额外global description不自动提供给Agent。mask-provided另建公平输入对照。GenEval2的vqa_list和其他评分字段只由评分进程加载。官方prompt→image_path字典每prompt只容纳一图；多seed必须分别运行并保存分数，不能覆盖同一个字典。

主比较的RL训练seed默认11、23、47，共享同一登记的双SFT起点；这些重复衡量RL采样/优化的随机性，SFT构建/初始化方差在SFT消融中另行报告。为控制实际硬件上的评测预算，主评测每任务固定外生seed101；另在预先选定的200个开发/专项测试任务上增加211、307、401三seed作稳健性评估。若扩展到全部benchmark四seed，单列三倍额外推理预算，各方法同样执行。相同任务/seed跨方法配对是评测方差控制，允许使用；在线训练兄弟仍独立。先给每seed结果与跨seed离散度；95%区间使用10,000次分层配对bootstrap，先重采训练seed再重采task/family/session，兄弟图和同任务不同seed图不当作独立样本。MagicBrush以原session为单位。主要比较B5对B2/B3/B4使用Holm校正，同时报告百分点差与区间。

人工审计共300对：B5对B2/B3/B4各100对；每个比较按两方法终评分均值的三分位分成互斥层，分别抽34/33/33对，固定seed且保存入样概率。左右顺序随机、方法匿名；两人独立判断任务完成、原图保留、身份一致和视觉质量，分歧第三人裁决。报告各层及按入样概率逆加权的总体胜/平/负、无法判定率、Cohen κ和聚类区间；不把过采样某层的原始比例当总体胜率。官方基准判据独立于内部32B reward；VLM间一致不等于真实正确，人工结论单独列出。

训练中每25轮离线审计50个输出，半数高reward、半数随机；每100轮进行一次分层人工核验。记录“训练判据通过但人工失败”的比例，以及漏计对象、模糊图像、文字伪证、背景改动和参考混淆。阈值或判据需要改变时结束旧reward版本、补校准、新stage启动，不把前后曲线当同一奖励尺度。

20.4 定位问题的执行顺序

现象	首先检查	处理与复验
loss有变化，图像不变	target切片、adapter激活、B梯度、条件hash	固定seed单步扰动参数和控制，验证velocity及图像响应
修复变成重新编辑更早源图	selected指针、历史source晚绑定、candidate绑定	SELECT→APPLY最小回归例；检查实际source artifact ID
高reward但计数/身份错	检测漏项、实体匹配、VLM校准、未知项分母	人工与结构化证据复核，冻结新判据后重测
RL长期零优势	兄弟seed是否相同、root/leaf分组、要求软分、任务难度	先toy梯度与独立性，再预定义难度层/纠错SFT；不删零组
Agent改进而DiT无变化	render是否为空、φ trainable集合、VJP负支、尺度	分开PG与reference KL；比较PG norm和参数差，重做梯度与LR pilot
rollout/replay logp差大	CFG、mask、IDs、GDN cache、RoPE、sigma、FP32状态	逐字段hash和逐层对齐；不直接扩大clip或减reward
5090 OOM或速度异常	SDPA backend、score矩阵、双支activation、缓存泄漏	§17顺序优化；记录峰值和时间，不以关控制掩盖
旧图选择后仍回报新图	finalize使用了隐藏best或最后生成指针	明确只用交付ID；对应image/evidence/hash断言
某rank拖慢或batch残缺	job重试、同版本ack、任务分配、过期worker	完整组恢复与超时配置，不以丢低分样本提速

训练可实施性的未决项是最大布局真实峰值、masked SDPA在两类卡的速度、判据的分类型可靠性、8,000对监督配额达成率、有效学习信号和实际网络利用率。每项都有上述独立验收与修复路径；这些测量用于决定实现参数和资源排期，不用于否定或缩减研究课题。

21. 源码差异、采用范围与具体修复

以下分类描述代码在指定配置下的行为，不推断作者意图，也不把论文中讨论的全部能力等同于公开仓库已经实现。

核验位置	判定与适用条件	本计划修复位置 / 验证
Transformers5.12.1 hybrid cache S26	recurrent初始化沿用conv dtype，可能把FLA FP32 state存成BF16；linear crop不能撤销状态	最小FP32 cache子类；每动作新prefill；完整prefix chunk replay；与上游后续修复核对
Qwen3.8 processor/template/forward S1 S3	架构是Qwen3_5 hybrid，默认thinking；EOS与PAD重合；无Qwen3-VL DeepStack	官方类/processor；显式模板开关；位置mask；冻结视觉前缀注入与真实位置重放
PEFT prepare_kbit及adapter切换 S5	非量化参数被转FP32；set_adapter改变requires_grad；量化merge不是恒等	显式精度恢复、496目标白名单、SFT adapter独立copy；同一量化底座不重建
Diffusers PeftAdapterMixin S5	set_adapter不接PeftModel的inference_mode参数	DiT独立add/set接口；显式reference冻结和policy白名单

核验位置	判定与适用条件	本计划修复位置 / 验证
Diffusers attention dispatch / PyTorch SDPA S25	native Flash拒非空mask；已有efficient backend支持mask，但实机kernel仍需验收	_native_efficient主路径；query行分块等价保底；不能静默改math/去mask
BFL 9B metadata/config S24	文本encoder是Qwen3-8B CausalLM，不是控制器；官方某路径FP8与本BF16条件不等价	整套9B快照、BF16冻结encoder；12288文本/4096 DiT；重新生成9B修复标签
Tencent diffusion.py31–111、287–346 S6	两支kwargs=None；缺负文本会跳过CFG负支；sde_indices同时控制注噪与保存	显式mask/IDs、负条件缺失报错；stochastic_steps全T、train_indices独立；同一velocity采样/replay
Tencent Qwen bundle.py38–94 S21	类名硬编码Qwen2.5，不能只换Qwen3 checkpoint字符串	新qwen35_actor.py使用Qwen3_5多模态类与NF4；完整mm_token_type_ids、grid、FP32 GDN cache与行为logp复核
Tencent bundle.py169–186、vae.py 70–132、track_builder.py738–756 S6	DiT-only已实现；通用SFT调用和Klein VAE签名/返回格式未闭合	klein_codec.py共用编码核心、区分target/reference包装；shape与decode往返
Tencent algorithms/sft.py195–320 S6	train未用eval的sample loss mask；非平凡mask场景有归约缺口；aux已detach	fm_loss.py返回有梯度逐样本loss，统一有效分母；4＋1拆批一致
G-U-N edit_grpo_trainer.py805–855 S8	CFG>1时rollout双支而replay仅正支，策略不一致	唯一velocity与顺序双支VJP；直接autograd对比
G-U-N 同文件213–253、504–534 S8	PEFT后解冻backbone/lm_head不符合本方案LoRA范围；尾批等权均值可偏	trainable allowlist＋全局分母；参数数与不等microbatch检查
RePlan flux_klein.py1050–1074、1158–1193 S7	访问image[0]限制纯T2I；多参考循环/索引存在该集成路径的尺寸或覆盖风险	先处理None、逐参考grid/offset、独立source/target变换；0/1/2参考矩阵
RePlan 同文件1299–1326、flex_attn.py 516–647 S7	正负文本布局不同；flex mask并非原生attention_mask	两支同布局；原生SDPA boolmask；签名检查与禁用边测试
Flow-GRPO SDE49–93与Kontext训练840–850 S9	返回噪声系数d；该KL写法未包含完整转移方差$d^2(-\Delta)$	§12的s^2解析核；不同Δ的KL Monte Carlo
ComfyUI execution.py733–801 S10	inference_mode为合理推理实现，不支持训练图；残余节点非精确SCC	自有训练replay；SCC拒环、ordered-slot缓存与分支历史
GroundingDINO CUDA分派65/135与包装330–350 S15	旧Tensor API在新torch需兼容补丁；无BF16核，CUDA输入不会自动回退CPU	tools/patches/groundingdino_torch26.patch，FP32 worker，编译/加载/前向参照验证
EMU rollout478–498、Gen-Searcher workflow602–618 S16	token对齐失败回退all-ones会污染监督；按唯一episode分组筛零奖不适合作RLOO组过滤	保留原token边界，坏记录隔离为infra；显式parent/group ID，完整组保留
状态cast与连续密度 S6 S8	需要核对采样动作与保存状态；保留原始连续动作可给扩展概率解释，不笼统判两仓库全错	本方案保存FP32完整状态/样本，BF16只用于网络输入；对每条路径逐项核验
UMM事务 / DiffusionNFT S11 S16	可借鉴事务与替代目标，未提供本文完整两机DAG联合实现	新增双侧COMMITTED协议；NFT仅单独目标对照

区别事实与设计：上表“判定”只限已读到的固定文件/分支；“修复”是本系统将采用的改动，尚未在GPU上运行。9B gated配置/权重未在本轮下载，结构来自官方公开定义和元数据；取得授权后strict load是启动门。论文叙述、README支持列表和已运行结果分别记录，不把一个文件的缺口扩大成整个项目无效。

实现者对每次移植保留原文件/函数、提交、修改diff与测试结果。既不照搬某一仓库，也不重写已经核对可靠的Transformer、VAE和processor。

22. 固定来源与检索定位

以下链接直接指向公开源码或模型配置。仓库提交为本次核验快照；官方硬件/安装文档是动态页面，本轮核验日期为2026年10月26–27日。实现时下载内容另记SHA256。行号帮助定位，函数与文件名是主要锚点。

- **S1｜27B控制器快照。**Qwen3.8-27B配置、权重索引、processor、模板、generation_config、模型卡。本轮另解析18个shard的JSON头与1199个shape，未下载权重载荷。
- **S2｜Klein Transformer。**9B固定模型快照与公开卡（配置/权重需授权；结构另由S24核对）；Diffusers Transformer：double processor325–391、投影526–545、kwarg过滤550–567、single processor569–625、融合投影745–763、timestep1231、IDs1268–1280。
- **S3｜Qwen3_5多模态forward。**modeling_qwen3_5.py：GDN371–557、full attention645–718、模型/ MTP812–824、视觉1018–1118、语言forward1137–1221、placeholder1446–1477、位置1490–1533、多模态注入1535–1608、generation位置1903–1918。复用Qwen3VLProcessor、图像processor。

- **S4 | Klein 编解码与 sigma。**pipeline_flux2_klein.py：shift63–78、文本 208–263、IDs265–365、patch/pack369–399、VAE462–475、采样811–880、decode904–918；FlowMatch scheduler。
- **S5 | PEFT与LoRA。**kbit准备、PeftModel.set_adapter、Diffusers adapter接口；初始化layer.py328–341、target匹配tuners_utils.py1894–1934。
- **S6 | Tencent UniRL。**固定树；diffusion.py、bundle.py、vae.py、track_builder.py、algorithms/sft.py、SDE kernels、trainer/pe.py。
- **S7 | RePlan。**flux_klein.py、flex_attn.py。区域编码 732–825、输入处理 1050–1074、参考 1158–1193、CFG1299–1326；flex import初始化28–32、processor516–647。
- **S8 | G-U-N UniRL。**Klein pipeline：SDE45–98、CFG333–357；edit_grpo_trainer.py：解冻213–253、归约504–534、replay805–855。
- **S9 | Flow-GRPO。**SDE/logp、Kontext KL。
- **S10 | ComfyUI。**graph.py：ready117–240、残余环375–392；caching.py83–149；execution.py 733–801。
- **S11 | UMM-Reflection事务。**v20_update_transaction.py，主要核验1–220行的更新阶段与状态检查。
- **S12 | MagicBrush。**数据固定版本、README、image_eval.py：最终turn165、全部turn208、DINO400；DINOv1 hubconf。
- **S13 | OmniEdit。**Filtered-1.2M固定数据卡，train1,202,797、dev700；下载清单、schema、评分字段和许可分别核对。
- **S14 | 官方评测。**GenEval summary_scores.py；GenEval2 evaluation.py：首token答案变体与计数处理73–145、几何均值187–188；800条数据、Tencent逐字节相同副本；官方Qwen3-VL-8B revision。
- **S15 | 视觉工具。**GroundingDINO inference.py53–99；SAM2 predictor85–129；DINOv2固定源码。

  工具安装定位：GroundingDINO CUDA核、Python dtype分支、torch2.6 Dispatch、SAM后处理。公开权重：GroundingDINO SwinT、SAM2.1 small、DINOv2 B/14、固定BERT。
- **S16 | 其他训练参考及局限。**DiffusionNFT SD3训练；EMU rollout；Gen-Searcher workflow。
- **S17 | 硬件和运行环境。**NVIDIA A6000数据表、RTX5090规格、GPU计算能力、CUDA兼容表、PyTorch版本安装表。
- **S22 | 训练模式与checkpoint。**Transformers GradientCheckpointingLayer，只在训练模式启用；冻结模块状态与current训练状态应分开。
- **S20 | Adam与RL配置。**PyTorch2.13 Adam更新；Flow-GRPO默认LR。用于核对外审步长论证与源码默认值，不把他项LR直接当本方案最优值。
- **S21 | Qwen3 worker集成缺口。**Tencent Qwen loader；Qwen3 processor。
- **S19 | OCR。**Tesseract5.5.0、tessdata_fast4.1.0。只用于本计划已校准的英文/数字任务；数据与二进制分开记录hash。
- **S23 | 冻结32B判据。**Qwen3-VL-32B配置、权重索引、processor；Qwen3-VL forward，DeepStack保留在判据自身路径。
- **S24 | 9B官方结构与文本编码。**BFL Klein9BParams、官方加载配置util.py、text_encoder.py、9B转换定义、官方img2img LoRA例。8B结构交叉核对Qwen3-8B配置；实际部署仍加载9B同快照打包encoder，不能只按名字替换。
- **S25 | masked attention真实后端。**Diffusers _native_efficient_attention3187–3219、PyTorch原生Flash mask检查259–266、CUDA efficient架构及dtype检查。源代码允许不等同于目标wheel/GPU实测通过。
- **S26 | NF4与GDN cache。**bnb量化、输入梯度、安装/架构说明、固定cache初始化、上游后续修复、FLA recurrent kernel、chunk kernel、causal-conv1d。
- **S27 | RLOO实现参考。**TRL rloo_trainer.py。采用独立重复采样和leave-one-out的实现经验；本文根/后缀分组与双模型score需自行按§13实现，不能以现成trainer替代推导。

23. 本轮真实核验记录与交付边界

23.1 已执行的源码、元数据与CPU检查

本轮重新阅读了27B的config、模板、processor、混合层forward、cache、PEFT、bitsandbytes和FLA；9B的官方结构、转换器、encoder、mask后端、SDE/训练路径；32B判据的配置和索引。直接来源见§22。27B采用HTTP Range读取全部18个safetensors shard的长度字段与JSON头，核对1199个shape和索引，没有下载完整权重。9B gated权重/config未越过权限获取；公开结构和公开参数元数据一致，真正strict load留在启动验收。

以下数值在CPU上真实执行或重新执行，使用NumPy浮点算术；它们不是模型性能实验。

检查	方法与实际结果
分层RLOO，同θ控制根与后缀	精确枚举1024个结果并与期望回报中心差分比较；θ score .020730804773 vs差分 .020730804740，ϕ .034420899272 vs .034420899353，最大绝对差8.09×10^{-11}
分层RLOO，含合法零render分支	精确枚举324个结果，根/后缀/renderer三种score期望与直接期望导数最大差1.249×10^{-16}，总概率.9999999999999998
顺序CFG VJP	D7小tanh双支模型，CFG4、负系数−3；与原Gaussian PG＋KL有限差分比较，最大差4.20×10^{-12}，相对L2 1.45×10^{-10}
冻结head位置分块VJP	11词、hidden3、完整因果前缀、PG＋全词表KL与EOS/padding；分块对一次性VJP差0；对有限差分最大差4.21×10^{-12}，相对L2 2.24×10^{-9}
四时间层抽步	T20/T50按层长/T加权期望与全时间均值差≤1.11×10^{-16}；T50错误等权得到.532770而正确均值.524120
phase/action SFT归约	配额5/7/5/3，插入mask0 padding及不等rank/空rank；原检查差0，另一随机不等切分差2.22×10^{-16}
Gaussian KL	500,000样本，std=.17、均值差=.025；解析.01081315，MC .01086738，差.261个标准误；错误分母在此例低16倍
sigma与转移std	T20/28/50全部sigma严格递减至0、方差正、首步std=.3；末步为.09209302/.06410270/.03184463
query行分块attention	NumPy全QK softmax与query块读取全K/V比较，最大差1.11×10^{-16}；不代表GPU后端已测
EOS与PAD边界	实际长度2的[20,248044,248044,248044]，位置mask保留2个token含EOS；按PAD ID会错误只留1个
27B结构与存储算术	496个LoRA目标、116,727,808参数；400个量化投影、24,326,963,200参数，与实际shape清单一致
9B结构算术	官方模块求和9,078,581,248，与公开参数元数据一致；112个LoRA目标、31,981,568参数；静态16.9102＋.5957GiB
32B判据算术	index对应33,357,390,064参数；448个量化投影31,205,621,760，静态NF4约19.00GiB
终止动作与奖励界	旧同图STOP比ACCEPT失败时多.05、成功相同；新FINISH成功保守下界.68、失败上界.3、全域[−1,1.3]
成本归约	单主路径48,768 renders；joint最多115,200重放转移；三支主比较93,600训练renders/seed

可复现的小环境。 第一项取$r \sim \text{Bernoulli}(\text{sigmoid}\theta)$，$a \sim \text{Bernoulli}(\text{sigmoid}(\theta + .7r))$，$z \sim \text{Bernoulli}(\text{sigmoid}(\phi + .4r - .3a))$；$R = \mathbf{1}[a = r] + .8\mathbf{1}[z = r] - .15a$，θ=.31、ϕ=−.27，N=M=2，中心差分步长10^{-6}。按§13根/后缀各自系数枚举两个根、每根两个(a,z)，覆盖一个θ同时影响两阶段的情形。

含零render的第二项取根logit .3、后缀是否render的logit$-.4 + .2r$、图像Bernoulli logit.$6 - .3r$。不render回报.$15 + .05r$；render时$z = r$回报1.0，否则−.05。精确枚举两个根各两条后缀的324种结果，直接导数为(.0342076777921, .0678066996559, .0253506372788)，RLOO得到同值。这验证零render分支不应从组中删除。

head检查seed=20261027，$X \in \mathbb{R}^{7\times4}$、$A \in \mathbb{R}^{4\times3}$分别由标准差.2的正态初始化，冻结$W \in \mathbb{R}^{11\times3}$标准差.3；decoder为$H = \tanh(\text{cumsum}(XA))$。取位置[2,3,4,5]，目标[0,10,8,9]，mask[1,1,1,0]，优势[.7,.7,−.2,−.2]，系数[1/120,1/120,1/240,1/240]，β=.02；reference用A+.03且停止梯度。每两位置一块，对A做中心差分10^{-6}。前缀中间梯度非零，故分块没有切掉前缀影响。

此外，Adam反例在999步零梯度后给梯度1，β=(.9,.999)、epsilon1e−8，第1000步位移为2.514566×LR；这说明不能用“每个参数每步至多移动LR”证明DiT必然不学习。实际改动仍采纳合理的更高LR pilot与更充分转

移预算，并以输出响应及任务效果检验，见 § 13、15。相同起点、终态势为零的势函数奖励在episode级RLOO中抵消；因此主目标不加入这一无效包装。

23.2 仍需真实GPU完成的项目

尚未运行27B/9B/32B完整模型、NF4质量对照、FLA cached/full概率一致性、masked efficient kernel、最大布局backward、服务吞吐、SFT或RL。CPU误差小不能推出这些门已经通过。尤其需要实施时确认：

- 9B授权快照的配置与strict load、打包encoder一致性。
- A6000的27B完整prefix QLoRA与FP32 GDN缓存是否达到概率/峰值门。
- 5090上带bool mask的efficient attention及双CFG VJP是否达到28GiB门。
- 32B量化判据的分类型校准与队列成本。
- 配对SFT几何相容率、真实修复标签质量及8,000配额实际达成数。
- 两侧任务PG、输出响应和同预算单组件/联合对照结果。

每项都已有 § 19的输入、阈值、修复顺序和记录要求。当前交付完成的是**经源码与数学核验、可以按模块逐项实施的设计**；没有把未来GPU验收、训练收益或墙钟时间写成实测。

23.3 研究路径保持完整

DAG把意图、可执行控制和视觉证据关联起来；同条件SFT让Agent与生成器学会使用共同接口；Agent RL学习真实闭环中的规划和修订；联合RL从同一任务结果同时调整两侧策略。错误节点定位、祖先/分支修订、身份与空间传递、回退和结束都保留在主系统中。接下来按 § 19完成实现，再由 § 20检验各阶段的实际作用；不需要以增加无关模块或更换课题来填补实现缺口。

23.4 最终一轮可执行性审查与定稿确认

最终结论：没有发现尚未处理的、足以使本计划按规范实施即失效的重大设计矛盾。v3 可以定稿，按 § 19进入实施。 本轮完整复读正文、对照最初外部审查，并分别复核模型运行、生成器与DAG、SFT/RL及联合梯度。重新联网取得固定源码，没有仅凭论文或上一轮结论作判断。本轮不改变主模型、训练目标、默认参数、DAG协议或资源分工；追加的是下面的核验记录。

最终审查范围	依据与结论
27B加载、量化与实际调用	官方config、HF forward/generation、PEFT与bnb实现一致；重新解析1199个权重shape，仍为496个LoRA目标、116,727,808个adapter参数；完整NF4副本的单卡分工成立。S1 S3 S5 S26
27B采样与有梯度重放	HF接受传入的修复后Cache；新token的多模态类型追加0、四轴位置延展；保存prefix视觉槽位的完整重放与实际生成语义一致。保留FP32 recurrent修复和head VJP，不添加新模型分支。
9B条件与运行路径	BFL/Diffusers/Tencent固定实现核对了12288维文本、128通道packed latent、target-first、参考time10/20、两种processor的mask传递和双支CFG。NumPy对非正方形、多通道张量执行patchify/pack及逆变换，逐元素精确相等。S2 S4 S6 S24 S25
原外审三项实质问题	CheckSpec与EvaluationSpec双通道已定义；φ的学习响应、LR pilot和单组件对照已安排；修复标签位于DiT SFT及sampler锁定之后，数据与判据成本已计账。未发现这些修复被换模型过程破坏。
SFT及联合概率	完整prefix、有效监督mask、全局分母、零render、所有实际render的score、全步正方差SDE、实际转移方差KL、两侧同版本一次更新相互闭合。新增多轮枚举见下文。S6 S9 S27
硬件与资源	重算27B底座及训练/reference状态为19.5053GiB，另加norm精度约1.54MiB；9B为16.9102＋0.5957GiB。两者均为静态量，已有42/28GiB实测峰值门；不增加跨机梯度同步或显存池假设。

补充的生成入口源码定位：HF接受自定义Cache、生成token的类型与位置延展。这些验证支持现有实现契约，没有新增必须修订项。

新增的多轮联合梯度验证。 在有限Bernoulli环境中令同一θ控制根计划、是否首次render、看见第一次图后的继续决策；同一φ控制两次render。设$s(x) = 1/(1 + e^{-x})$，θ=.27、φ=−.31：

$$
\begin{aligned}
r &\sim \text{Bernoulli}(s(\theta)),\\
u \mid r &\sim \text{Bernoulli}(s(\theta - .3r)),\\
y \mid r, u = 1 &\sim \text{Bernoulli}(s(\phi + .4r)),\\
v \mid r, y, u = 1 &\sim \text{Bernoulli}(s(\theta + .8y - .5)),\\
z \mid r, y, u = v = 1 &\sim \text{Bernoulli}(s(\phi - .6y + .2r)).
\end{aligned}
$$

$u = 0$时零render且$R = .14 + .07r$；$u = 1, v = 0$时交付第一次图且$R = .85y + .12r - .08$；$u = v = 1$时交付第二次图且$R = 1.1z + .2\mathbf{1}[z = r] - .16 - .09y$。每个根有7个后缀结果；取N=M=2，完整枚举9,604个组合，并以步长10^{-5}做中心有限差分：

检查	本轮实际CPU结果
组合总概率	1.0000000000000069
直接期望的θ、ϕ score导数	(.03971170210184353, .10282906553219126)
分层RLOO的θ、ϕ期望	(.039711702101844146, .10282906553219191)
RLOO与直接score最大绝对差	6.52×10^{-16}
有限差分与直接score最大绝对差	1.14×10^{-12}
错删被放弃但影响后继的第一次render score时，ϕ梯度偏差	.009262809558049229

结果支持§11–13已经采用的“保留全部实际生成的score”与分层基线；不存在为了最终图而遗漏中间图梯度的缺口。另重新运行了§23.1的合法零render枚举、完整前缀head VJP、SFT归约和预算检查，结果保持一致。以上均为源码/元数据及CPU算术检查，没有加载模型、实现研究系统或启动训练。

定稿后的下一步是按既定启动门实施，不再继续扩展设计审查。 真实模型strict load、GPU算子/峰值、采样质量和学习收益仍须上机取得证据；这些事项已给出具体入口、门槛和修复顺序，不是留给实施者自行补齐的设计空白。基础运行与正常生成可据此逐项验收；SFT、Agent RL和联合训练各自改善多少，按§20的公平对照形成实际结论。